Horizon-Router：面向未来空域需求感知的多时域层级区域航空轨迹概率预测

作者信息待补充

摘要

未来空域需求感知需要在较长提前量上估计航空器可能占用的区域，并给出可用于聚合、排序和风险分析的概率分布。本文研究多时域层级区域航空轨迹概率预测：基于 ADRR 派生的一个月商业航班轨迹数据构建 20,712,602 个预测窗口，给定按 5 分钟重采样的 30 分钟历史轨迹，同时预测未来 10、30、60 和 120 分钟的 H3 区域概率。为避免把长时不确定性压缩成单一路径，本文采用 coarse-to-fine H3 输出协议，先预测父层区域，再在父层条件下恢复细粒度区域概率。方法上，本文提出多尺度 horizon-query 编码器，使每个预测时域分别从细尺度历史序列和 stride-pooled 粗尺度序列中检索时间证据。在此基础上，本文提出 Horizon-Router 单模型，用 global、coarse-stable 和 local-causal 三个内部 expert 表达不同时间尺度的运动证据，并由 horizon-level router 为每个预测时域自适应融合。训练阶段进一步引入基于 expert loss 的 router supervision、活跃 expert mask、负载均衡、expert auxiliary loss 和 horizon-wise teacher distillation，以缓解专家塌缩并稳定大规模训练。完整数据集结果显示，Horizon-Router 的宏平均 top-1/top-5 达到 0.6884/0.9710，NLL、Brier 和 ECE 分别为 0.9399、0.4262 和 0.0104；相较适配后的 TrAISformer-H3 强基线，模型在 top-1、top-5、NLL 和 Brier 上均取得提升。这些结果表明，面向未来空域需求感知的长时航空预测可以被有效表述为层级区域概率建模问题，而时域级专家路由为不同提前量下的历史证据选择提供了有效结构。

关键词：航空轨迹预测；空域需求感知；H3 空间索引；多时域预测；概率预测；专家路由

1 引言

未来空域需求感知是轨迹化运行和空中交通流量管理中的基础环节。Trajectory Based Operations（TBO）把航空器轨迹作为跨系统共享的运行对象；在日运行阶段，一组航班在未来若干提前量上的位置分布刻画了空域需求，并影响流量管理措施、约束点调度和需求–容量平衡 [1, 2]。已有 ATM 研究也表明，轨迹预测误差和不确定性会传递到 Traffic Flow Management 操作、管制自动化工具和不利天气下的拥堵预测中 [3–6]。因此，长时航空预测不只需要回答“最可能在哪里”，还需要回答“哪些区域可能被占用、概率质量如何分布、置信度是否可靠”。

开放飞行监视网络和运行档案使这一问题具备了大规模、可复现的研究条件。OpenSky Network 证明了众包 ADS-B 传感网络可以长期支撑航空数据研究 [7]，OpenSky 2019–2020 数据集进一步展示了开放历史航班数据在跨区域、长时间跨度研究中的价值 [8]。EUROCONTROL 的 Aviation Data Repository for Research（ADRR）提供面向研究和开发的商业航班运行档案 [9]。这些数据源把航空轨迹预测从小规模局部样本推进到统一协议下的大规模建模，也使区域级概率输出可以被系统评价。

现有数据驱动航空轨迹预测多以连续坐标或四维点轨迹为输出。Attention-LSTM、Attention-TCN-GRU 和 WTFTP 等方法说明，注意力、时序卷积、循环结构和时频建模可以提高四维轨迹预测性能 [10–12]；WTFTP+ 和 FlightBERT++ 则进一步把航空预测推进到多时域设置 [13, 14]。这些工作为时间建模提供了重要基础，但当提前量扩展到 60–120 分钟，并且目标转向区域需求感知时，点轨迹输出会把多模态未来压缩为单一路径，排序质量、似然和校准性也难以在同一离散概率空间中比较。

本文研究*多时域层级区域航空轨迹概率预测*。给定 30 分钟历史监视轨迹和轻量上下文，模型在未来 10、30、60 和 120 分钟输出 H3 区域概率分布。H3 属于离散全球网格系统的一种工程实现，具有层级索引、父子映射和邻域操作等接口 [15, 16]。本文采用 coarse-to-fine 输出协议：短时预测使用较细目标分辨率，长时预测使用更粗空间支撑；模型先预测父层区域，再在父层条件下恢复细粒度区域概率。这样既控制了输出类别规模，也让 top-k 命中率、NLL、Brier 分数和 ECE 可以在同一层级概率协议下报告 [17–19]。

方法上，本文的核心问题是不同预测提前量需要不同的历史证据。10 分钟预测更依赖最近机动和局部连续性，60–120 分钟预测更依赖粗尺度趋势和阶段性演化；把所有 horizon 压到同一个历史摘要上，会削弱这种差异。为此，本文首先提出多尺度 horizon-query 编码器：每个 horizon query 同时检索细尺度 Transformer 历史序列和 stride-pooled 粗尺度历史序列。进一步地，本文提出 Horizon-Router，在一个单模型内部组织 global、coarse-stable 和 local-causal 三个 expert，并由 horizon-level router 为每个预测时域自适应融合三类证据。这一设计承接多时域预测中 horizon-aware 解码的思想 [20, 21]，也与 mixture-of-experts 文献中由门控网络组织局部专家的建模谱系一致 [22–24]。

仅加入 expert routing 并不足以保证稳定训练。大规模路由模型容易出现专家塌缩或 router 权重过早固化，尤其是在不同 horizon 的标签可用性和类别规模并不完全一致时。本文因此引入一组与训练目标直接耦合的路由约束：根据各 expert 在当前 batch 上的粗区域、子区域和状态损失构造 soft router target；用 active expert mask 限定 local-causal expert 只服务短时 horizon；用 load balancing 和 expert auxiliary loss 保持专家可训练；再用 horizon-wise teacher distillation 从若干强神经专家的混合预测中传递概率信息。知识蒸馏和模型压缩已有成熟基础 [25–27]，本文将其用于层级 H3 区域概率输出和时域级路由训练。

本文主要贡献如下：

1. 提出多尺度 horizon-query 编码器，使每个预测时域分别从细尺度历史序列和粗尺度池化序列中检索时间证据，避免所有 horizon 共用单一历史摘要。
2. 提出 Horizon-Router 单模型，在统一 coarse-to-fine H3 输出头下融合 global、coarse-stable 和 local-causal 三个内部 expert，用 horizon-level router 建模不同提前量对历史证据的差异化需求。
3. 引入面向路由训练的 loss-aware regularization 与 horizon-wise distillation，并在 20,712,602 个 ADRR 派生预测窗口上，与 Markov、层级 GRU、Transformer horizon decoder、Multiscale Transformer、TrAISformer-H3 和 FlightBERT++-H3 等基线进行完整规模比较。

2 相关工作

2.1 航空轨迹预测与未来空域需求感知

航空轨迹预测长期服务于运行态势、需求–容量平衡和交通流量管理。TBO 将轨迹作为跨系统协同的核心对象，日运行阶段的轨迹集合则刻画未来空域需求，并支撑 traffic management actions、约束点调度和容量管理 [1, 2]。在这一背景下，预测误差不是孤立的模型误差。Reisman 等分析了战术轨迹精度对 TFM 操作的影响 [3]，Mercer 等研究了轨迹预测不确定性对管制员表现和工具可接受性的影响 [4]。围绕更高层的流量管理，Chen 等使用机会约束优化处理不确定性下的 ATFM 问题 [5]，Tobaruela 等提出 air traffic predictability framework 以分析交通可预测性及其应用 [28]。近期不利天气下的空中交通拥堵预测也说明，未来空域需求判断需要显式处理运行不确定性 [6]。

本文与上述 ATM 工作的连接点在于概率化的未来区域占用，而不是直接求解 ATFM 优化。本文学习单架航空器在多个提前量上的区域概率分布；这些分布可以进一步聚合为空域需求图，也可以用于区域排序和热点识别。因此，本文把运行需求中的“不确定未来占用”转化为可训练、可比较的层级区域概率预测问题。

2.2 数据驱动航空轨迹预测与多时域建模

数据驱动航空轨迹预测从物理外推和统计模型逐步转向深度时序表示学习。已有综述将民航四维轨迹预测方法按物理模型、统计模型和深度学习模型归类，并指出数据质量、泛化能力和不确定性量化仍是主要挑战 [29, 30]。在深度模型中，Attention-LSTM 将注意力机制用于四维轨迹预测 [10]，Attention-TCN-GRU 结合时序卷积、GRU 和注意力模块建模航空器状态演化 [11]。WTFTP 通过时频小波变换刻画轨迹中的全局与局部模式 [12]，WTFTP+ 将这一思路扩展到多时域飞行轨迹预测 [13]。FlightBERT++ 采用非自回归多时域框架，通过 horizon-aware context generator 和 differential-prompted decoder 直接预测多个提前量上的飞行状态 [14]。

另一些工作关注观测条件本身。Li 等面向噪声 ADS-B 数据提出自回归 Transformer 与混合位置编码 [31]，Shan 等研究稀疏卫星观测下的航空轨迹预测框架 [32]。这些研究共同表明，航空预测中的时间表示、观测质量和多时域输出需要被同时考虑。本文沿用多时域建模的基本问题意识，但将输出从连续坐标序列改为层级 H3 区域概率，从而把评价重点扩展到似然质量和概率校准。

2.3 开放监视数据、运行语义与区域化建模

开放飞行数据基础设施为大规模可复现研究提供了条件。OpenSky Network 是面向研究的大规模 ADS-B 传感网络 [7]，其 2019–2020 数据集覆盖大范围历史航班数据，并被用于多类航空运行研究 [8]。OpenSky 相关研究还讨论了众包空中交通数据的研究使用和社会影响 [33]。在流量管理系统中，运行数据质量本身也会影响 TFM 决策分析 [34]。ADRR 则提供面向研究和开发的商业航班运行档案，包含结构化轨迹与运行信息 [9]。

监视数据建模也常与意图推断、计划提取和一致性监测相连。Krozel 研究了 free flight aircraft 的 intent inference [35]，Foo 等将 intent inference 用于 surveillance 和 conformance monitoring [36]，Yang 等基于在线轨迹聚类进行终端区航空器意图推断 [37]。Lee 和 Lee 从记录的 ADS-B 轨迹中提取 flight plans，说明历史轨迹可以恢复更高层的运行结构 [38]。本文没有把预测目标写成计划恢复或语义解释，而是把监视轨迹转化为未来区域概率分布；这种表述更贴近下游区域占用、计划一致性和异常监测所需的空间输入。

2.4 层级空间表示、离散轨迹建模与多尺度时间编码

区域化输出需要合适的空间离散化。离散全球网格系统为大范围、多分辨率空间表示提供了通用框架 [15]，H3 则提供层级六边形索引、父子映射和邻域操作接口 [16]。在轨迹建模中，离散 token 表示也已被用于非航空场景；例如 TrAISformer 将 AIS 船舶轨迹离散化为 token，并使用 Transformer 学习序列分布 [39]。本文将 H3 层级网格用于航空区域预测：历史轨迹以 H3 token 和父层 token 输入，输出端以父区域和条件子区域分布表达不同 horizon 的空间不确定性。

多时域预测还要求模型按提前量读取不同历史证据。Temporal Fusion Transformer 将局部序列处理、门控机制和注意力结合，用于可解释多时域时间序列预测 [20]。MQTransformer 进一步提出 context-dependent decoder-encoder attention，避免所有 horizon 共享同一压缩上下文 [21]。这些工作说明，多时域预测不应只依赖单个共享摘要。本文的多尺度 horizon-query 编码器沿着这一方向前进：每个 horizon query 同时访问细尺度历史序列和粗尺度池化序列，使短时和长时预测可以使用不同粒度的时间证据。

2.5 概率校准、专家路由与蒸馏训练

区域概率预测需要比 top-k 命中率更完整的评价。Gneiting 和 Raftery 系统讨论了严格适定评分规则，强调概率预测需要同时考虑校准性和尖锐性 [17]。Brier 分数是概率事件预测中的经典二次评分规则 [18]。在深度学习模型中，Guo 等指出高准确率神经网络仍可能存在明显误校准 [19]。这些结论直接影响本文的评价协议：区域预测模型不能只用 top-k 命中率排序，还应同时报告 NLL、Brier 和 ECE，以区分“命中更多目标”和“给出更可信概率分布”。

本文方法还与 mixture-of-experts 和 routing 文献相关。Jacobs 等提出 adaptive mixtures of local experts，用门控网络组合多个局部专家 [22]；Shazeer 等将 sparsely-gated MoE 引入大规模神经网络 [23]；Switch Transformer 进一步展示了稀疏专家路由在大模型训练中的可扩展性 [24]。这些工作关注通用路由机制，本文则把路由粒度落到预测 horizon：global、coarse-stable 和 local-causal 三个 expert 分别覆盖完整历史多尺度趋势、粗尺度稳定演化和短时局部机动。

路由模型的训练也与知识蒸馏和模型压缩相关。Bucila 等提出通过压缩模型逼近大模型或集成的预测行为 [25]，Hinton 等系统化了用 softened targets 蒸馏神经网络知识的做法 [26]，Born Again Neural Networks 进一步显示同结构教师也可以改进学生模型 [27]。本文借鉴的是这种“用教师概率分布稳定学生训练”的思想，但把蒸馏目标放在层级 H3 粗区域、条件子区域和状态输出上，并与基于 expert loss 的 router supervision、active expert mask 和负载均衡共同使用。

3 问题定义

设历史窗口为

$$X = \{z_1, z_2, \ldots, z_T\}, \qquad T = 6, \tag{1}$$

其中 $T = 6$ 对应 30 分钟历史在 5 分钟采样间隔下的 6 个重采样时刻。每个时间步 $z_t = (r_t, p_t, u_t, m_t)$ 包含四类输入：输入分辨率 H3 区域 id r_t、其父层 H3 区域 id p_t、数值特征向量 $u_t \in \mathbb{R}^{18}$，以及 mask 向量 $m_t \in \{0,1\}^2$。本文沿用项目既有特征构造流程：数值特征覆盖位置正余弦编码、位移与距离增量、航迹方向、区域切换、飞行高度、速度、航向、垂直速度、时间间隔和地面状态；mask 特征为 `observed_flag` 与 `gap_flag`。此外，每个样本还包含一个上下文向量 $c \in \mathbb{R}^9$，其中编码了时刻周期、当前位置以及项目既有的目标标识哈希特征。

预测时域集合记为

$$\mathcal{H} = \{10, 30, 60, 120\} \text{ minutes}. \tag{2}$$

对每个时域 $h_j \in \mathcal{H}$，模型需要同时输出：（1）粗粒度 H3 区域标签 $y_j^{(c)}$；（2）在粗区域条件下的细粒度子区域标签 $y_j^{(f)}$；（3）状态标签 $s_j \in \{\text{airborne}, \text{landed}\}$。在本文的完整实验中，细粒度目标分辨率为 $[3, 3, 2, 2]$，对应粗粒度分辨率为 $[2, 2, 1, 1]$。因此，短时预测保持更细的空间粒度，而 60 和 120 分钟时域使用更粗的空间支撑以匹配增长的不确定性。

细粒度区域预测被写成层级条件分解：

$$p(y_j^{(c)}, y_j^{(f)}, s_j \mid X, c, h_j) = p(s_j \mid X, c, h_j)\, p(y_j^{(c)} \mid X, c, h_j)\, p(y_j^{(f)} \mid y_j^{(c)}, X, c, h_j). \tag{3}$$

这种分解与 H3 的父子层级一致，也使模型能够在较大输出空间上保持可训练的类别规模。对于某些样本，较长时域的未来标签可能因 mission 截断而不可用。项目实现中为每个时域维护有效性掩码 $v_j \in \{0, 1\}$，仅在 $v_j = 1$ 时累计损失和评价指标。

训练目标由粗区域分类、细区域分类和状态分类三部分构成。记 $\mathcal{V}$ 为有效 horizon 集合，则单样本损失写为

$$\mathcal{L} = \frac{1}{|\mathcal{V}|} \sum_{j \in \mathcal{V}} \left[\ell_{\text{coarse}}^{(j)} + \ell_{\text{child}}^{(j)} + \ell_{\text{status}}^{(j)} \right] \; + \; \lambda_{\text{cons}} \mathcal{L}_{\text{cons}}, \tag{4}$$

其中三项基本损失均为交叉熵；$\ell_{\text{child}}^{(j)}$ 仅在对应父区域下的子类标签有效时计算；$\mathcal{L}_{\text{cons}}$ 是可选的相邻 horizon 解码特征一致性正则。最终报告模型中 $\lambda_{\text{cons}} = 0$，即不启用该正则项。

给定每个时域上的细粒度区域概率 π_j 后，本文从区域排序和概率质量两个层面评价模型。区域排序指标使用 top-1 和 top-5 命中率，分别刻画模型最可能区域的正确性和前列概率质量是否覆盖真实区域。概率质量指标包括负对数似然（NLL）、Brier 分数和期望校准误差（ECE）。NLL 评价模型赋予真实区域的对数概率，Brier 分数评价完整离散概率分布与 one-hot 真值之间的二次误差，ECE 则使用 10 个置信度 bin 估计预测置信度与经验准确率之间的差异。本文主结果只使用这些直接由概率分布定义的指标；预测集合面积等空间范围评价留作后续在更明确协议下单独设计。

4 方法

4.1 总体思路

本文方法建立在统一的层级 H3 区域预测框架上。输入端，历史轨迹被编码为区域 token、父层区域 token、数值运动特征、mask 特征和轻量上下文；输出端，所有模型共享 coarse-to-fine H3 输出头，先预测父层区域，再在父层条件下预测子区域分布。这样可以把研究重点放在时间证据如何被读取和融合上，而不是把收益混入不同输出空间或评价口径。

Horizon-Router 的核心思路是把“不同提前量需要不同历史证据”显式写进模型。模型首先用多尺度 horizon-query 编码器为每个预测时域读取细尺度和粗尺度历史证据；随后用三个 expert 表达不同时间尺度的运动信息，并由 horizon-level router 生成时域相关的融合权重。推理阶段，融合后的特征进入共享层级 H3 输出头，得到每个 horizon 上的细粒度区域概率。

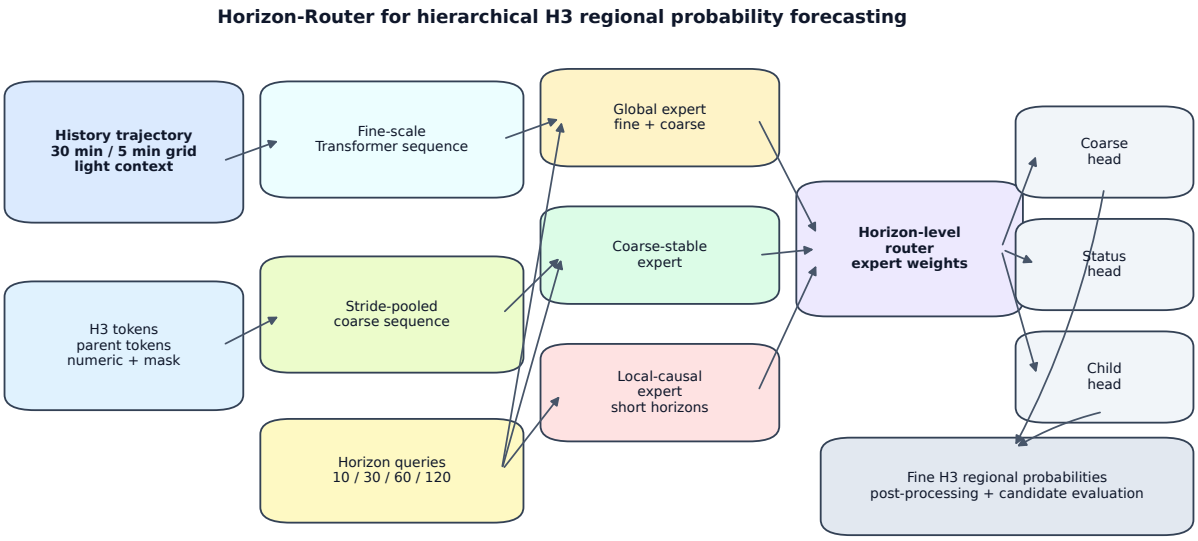


图 1: Horizon-Router 方法总览。历史轨迹和轻量上下文首先被编码为 H3/父层 token 与数值特征；多尺度 horizon-query 编码器为每个预测时域检索细尺度和粗尺度历史证据；global、coarse-stable 和 local-causal 三个 expert 经 horizon-level router 融合后，进入 coarse、status 和 child heads，输出层级 H3 区域概率。

4.2 输入表示与层级 H3 输出

对每个历史时间步 $z_t = (r_t, p_t, u_t, m_t)$，模型分别学习输入区域 embedding、父层区域 embedding，并将数值特征和 mask 特征线性投影到同一隐空间：

$$\tilde{z}_t = [E_r(r_t); E_p(p_t); W_u u_t; W_m m_t]. \tag{5}$$

其中 r_t 是输入分辨率 H3 cell，p_t 是其父层 cell，u_t 包含位置、位移、高度、速度、航向、时间间隔等数值特征，m_t 包含 `observed_flag` 与 `gap_flag`。模型根据观测标记、缺口标记和 unknown token 构造时间有效掩码；该掩码被 Transformer attention、池化和局部编码模块共享，用于抑制填充片段和缺口补齐片段的影响。样本级上下文 c 经过单独线性层投影后参与后续编码。

对每个预测时域 h_j，层级输出头预测粗区域、状态和条件子区域：

$$p(y_j^{(c)}, y_j^{(f)}, s_j \mid X, c, h_j) = p(s_j \mid X, c, h_j) p(y_j^{(c)} \mid X, c, h_j) p(y_j^{(f)} \mid y_j^{(c)}, X, c, h_j). \tag{6}$$

训练时，子区域交叉熵使用真值粗区域标签作为条件，以稳定学习父子层级对应关系。推理时，模型从粗区域分布中选取 top-K_j 个父区域，再计算每个父区域下的条件子分布，并将父层概率质量散射到细粒度 H3 cell。本文完整实验中使用的父层 top-K 为 $[64, 48, 48, 12]$。

4.3 多尺度 Horizon-Query 编码器

单一历史摘要难以同时服务 10 分钟和 120 分钟预测。本文先用带有效掩码的 Transformer encoder 得到细尺度历史序列

$$H^{(f)} = \mathrm{Enc}(W_z \tilde{Z} + P), \tag{7}$$

并通过 masked mean pooling 与上下文投影拼接为共享基特征 b。随后，模型按 stride = 2 对 $H^{(f)}$ 做带掩码的局部均值池化，再经一个粗尺度 Transformer encoder 得到

$$H^{(c)} = \mathrm{Enc}_c(\mathrm{Pool}(H^{(f)})). \tag{8}$$

对每个 horizon，模型维护可学习 horizon embedding e_j，并构造时域查询向量

$$q_j = W_q[b; e_j]. \tag{9}$$

该查询分别对细尺度序列和粗尺度序列做交叉注意力：

$$\alpha_j^{(f)} = \mathrm{softmax}(q_j {H^{(f)}}^\top), \qquad \alpha_j^{(c)} = \mathrm{softmax}(q_j {H^{(c)}}^\top), \tag{10}$$

$$z_j^{(f)} = \alpha_j^{(f)} H^{(f)}, \qquad z_j^{(c)} = \alpha_j^{(c)} H^{(c)}. \tag{11}$$

多尺度 horizon-query 特征写为

$$g_j = \phi_g([b; z_j^{(f)}; z_j^{(c)}; e_j]). \tag{12}$$

这里的 g_j 同时也是 Horizon-Router 中的 global expert：它保留完整历史、细尺度注意力和粗尺度注意力，是 warm-start 时最强的单路径预测分支。

4.4 Horizon-Router 三专家融合

Horizon-Router 在 global expert 之外加入两个分工明确的 expert。coarse-stable expert 只依赖粗尺度序列摘要和粗尺度注意力：

$$c_j = \phi_c([b^{(c)}; z_j^{(c)}; e_j]), \tag{13}$$

其中 $b^{(c)}$ 是粗尺度序列的 masked mean pooling 与上下文投影拼接。该分支强调阶段性趋势和粗粒度稳定演化，主要服务中长时域预测。

local-causal expert 只读取最近若干历史步，并使用因果 Transformer encoder 抑制对未来位置的泄漏。设最近局部序列为 $H^{(\ell)}$，则短时 horizon 的局部特征为

$$\ell_j = \phi_\ell([b; z_j^{(\ell)}; e_j]), \qquad z_j^{(\ell)} = \mathrm{Attn}(q_j, H^{(\ell)}). \tag{14}$$

在实现中，local-causal expert 只对预设的短时 horizon 激活；对更长 horizon，该分支通过 active expert mask 被置为不可用。这个边界很重要：局部机动对 10 或 30 分钟预测有价值，但不应被强行解释为 120 分钟区域需求的主证据。

router 在每个 horizon 上读取三个 expert 特征和 horizon embedding，输出融合权重：

$$w_j = \mathrm{softmax}(R([g_j; c_j; \ell_j; e_j])) \in \mathbb{R}^3. \tag{15}$$

最终解码特征为

$$d_j = w_{j,g} g_j + w_{j,c} c_j + w_{j,\ell} \ell_j. \tag{16}$$

d_j 被送入共享的粗区域头、状态头和条件子区域头。与简单加深单一路径编码器相比，这一结构让模型可以在时域层面选择历史证据来源，而不必要求所有 horizon 使用同一种时间摘要。

4.5 训练目标与路由约束

基础层级损失由粗区域、子区域和状态交叉熵组成。设 $\mathcal{V}$ 为 batch 中有效 horizon 集合，则

$$\mathcal{L}_{\text{hier}} = \frac{1}{|\mathcal{V}|} \sum_{j \in \mathcal{V}} \left(\mathcal{L}_{\text{coarse}}^{(j)} + \mathcal{L}_{\text{child}}^{(j)} + \mathcal{L}_{\text{status}}^{(j)} \right). \tag{17}$$

为了避免 router 过早偏向单一 expert，本文加入 loss-aware router supervision。对每个有效 horizon 和每个 active expert，模型临时用该 expert 特征通过共享输出头计算 expert loss $L_{j,e}$，并构造 soft target：

$$\hat{w}_{j,e} = \frac{\exp(-L_{j,e}/\tau)}{\sum_{e' \in \mathcal{A}_j} \exp(-L_{j,e'}/\tau)}. \tag{18}$$

其中 $\mathcal{A}_j$ 是 horizon j 上的 active expert 集合，τ 是 router supervision temperature。router supervision 最小化 $\hat{w}_j$ 与 w_j 之间的 KL 散度。active expert mask 用于屏蔽长时域上的 local-causal expert，避免该分支在不适用的 horizon 上接受错误激励。

本文还加入两个轻量约束。load balancing loss 将 router 权重拉向 active expert 上的均匀分布，防止单个 expert 长期占用全部概率质量；expert auxiliary loss 对 coarse-stable 和可用的 local-causal 分支施加输出头辅助监督，使这些分支即便未被 router 频繁选择也能保持可训练。global expert 通过主输出路径接受监督。

最后，模型使用 horizon-wise teacher distillation 稳定概率输出。训练时，从若干与层级输出兼容的强神经专家中按 horizon 构造混合教师分布，并对学生模型的 coarse、child 和 status 概率施加 KL 蒸馏项。总目标可写为

$$\mathcal{L} = \mathcal{L}_{\text{hier}} + \lambda_{\text{route}}\mathcal{L}_{\text{route}} + \lambda_{\text{bal}}\mathcal{L}_{\text{bal}} + \lambda_{\text{aux}}\mathcal{L}_{\text{aux}} + \lambda_{\text{distill}}\mathcal{L}_{\text{distill}}. \tag{19}$$

完整实验使用的权重为：$\lambda_{\text{distill}} = 0.08$，状态蒸馏权重 0.01，$\lambda_{\text{route}} = 0.08$，$\lambda_{\text{bal}} = 0.02$，$\lambda_{\text{aux}} = 0.05$，router supervision temperature 为 0.7。

4.6 推理概率支撑

推理阶段，模型先从粗区域分布中保留每个 horizon 的 top-K_j 父区域，再在这些父区域下展开条件子区域概率，并将父层概率质量散射回细粒度 H3 cell。为避免将概率分配给明显超出运动学范围的区域，本文在所有模型上使用相同的可达性掩码。该掩码根据当前 H3 cell 中心到目标 cell 中心的球面距离构造；若某目标 cell 的距离超过

$$d_{\max}(h_j) = v_{\max} \cdot 1.852 \cdot \frac{h_j}{60} + \Delta, \tag{20}$$

则其概率被置零并重新归一化。本文默认采用 $v_{\max} = 750$ knots、$\Delta = 250$ km。该步骤只作为统一推理约束，不参与训练，也不作为 Horizon-Router 的方法贡献。

5 实验设置

5.1 研究问题

实验围绕三个问题展开。Q1：Horizon-Router 在完整规模数据上是否超过外部适配强基线和内部结构基线？Q2：性能收益来自多尺度 horizon-query 编码，还是来自后续 expert routing？Q3：在完整规模训练下，horizon-wise distillation 和 loss-aware routing regularization 是否分别改善路由模型？

5.2 数据与划分协议

实验使用基于 ADRR 构建的 2024 年 3 月商业航班轨迹档案。按照项目既有流程，原始记录先按 90 分钟时间缺口切分为 mission，并对不超过 30 分钟的局部缺口做规则化处理；随后轨迹被重采样到 5 分钟时间网格，并构造区域、数值、mask 和上下文特征。为避免过短或信息不足的片段进入训练集，本文要求有效轨迹段至少包含 8 个重采样点。

处理完成后，数据集中共有 20,712,602 个预测窗口，其中训练集、验证集和测试集分别包含 14,505,637、3,108,933 和 3,098,032 个窗口。本文按航空器 id 进行 train/val/test 划分，从而减少同一航空器的重复运行模式同时出现在训练和测试中的风险。

5.3 时间与空间协议

所有模型统一使用 30 分钟历史、5 分钟采样间隔和 4 个预测时域 $\{10, 30, 60, 120\}$ 分钟。输入历史长度为 6 个时间步。空间离散化基于 H3：输入区域分辨率为 3，其父层输入分辨率为 2；目标细粒度分辨率为 $[3, 3, 2, 2]$，对应粗粒度分辨率为 $[2, 2, 1, 1]$。这一设置使 10 和 30 分钟预测保留较细空间粒度，而 60 和 120 分钟预测在更宽的空间支撑上建模未来不确定性。层级推理阶段，粗区域 top-K 值统一设置为 $[64, 48, 48, 12]$。

5.4 比较模型

本文报告七类模型。

1. **Markov baseline**：以当前输入区域为状态，统计从当前区域到未来区域和未来状态的经验转移频次，并使用加一平滑得到各 horizon 上的区域和状态概率。
2. **Hierarchical GRU**：项目原始层级区域预测基线，使用共享 GRU 时间摘要和 coarse-to-fine H3 输出头。
3. **Transformer Horizon Decoder**：在层级 H3 输出头不变的条件下，用单尺度 horizon-query Transformer 替代 GRU 共享时间摘要。
4. **Multiscale Transformer**：在单尺度 horizon-query 基础上加入 stride-pooled 粗尺度时间分支。
5. **Horizon-Router**：本文最终模型，在 Multiscale Transformer 基础上加入 global、coarse-stable 和 local-causal 三专家，以及 horizon-level router、路由正则和蒸馏训练。
6. **TrAISformer-H3**：保留 TrAISformer 风格的因果离散序列建模结构，并将输出端适配为本文统一的层级 H3 输出头。
7. **FlightBERT++-H3**：保留 FlightBERT++ 风格的非自回归 encoder-decoder 多 horizon 解码结构，并将原始飞行状态输出替换为本文统一的层级 H3 输出头。

TrAISformer-H3 和 FlightBERT++-H3 是适配基线，而不是原论文任务的逐字复现。为了保证比较口径一致，所有方法固定输入历史、预测时域、H3 输出空间、层级损失和评价指标，只允许时间建模主干及其稳定收敛所需的训练超参数不同。

5.5 训练设置

所有神经模型均使用 AdamW、固定随机种子 42、混合精度训练和早停策略。GRU 基线沿用项目原始 full 配置。Transformer Horizon Decoder 和 Multiscale Transformer 使用 batch size 1024、8

模型	Top1	Top5	NLL	Brier	ECE
Markov 基线	0.3184	0.7587	2.2788	0.8111	0.0323
层级 GRU	0.6648	0.9631	1.0214	0.4578	0.0180
TrAISformer-H3	0.6803	0.9697	0.9556	0.4361	0.0094
FlightBERT++-H3	0.6764	0.9671	0.9791	0.4417	**0.0086**
Transformer horizon decoder	0.6744	0.9656	0.9946	0.4447	0.0123
Multiscale Transformer	0.6827	0.9685	0.9641	0.4338	0.0093
Horizon-Router	**0.6884**	**0.9710**	**0.9399**	**0.4262**	0.0104

表 1: 完整规模测试集上的宏平均比较。Horizon-Router 在 top-1、top-5、NLL 和 Brier 上取得最优结果，并保持较低 ECE。

个 DataLoader workers、学习率 1.5×10^{-4}、weight decay 10^{-4}、梯度裁剪 1.0、ReduceLROnPlateau 调度器和 early stopping。Horizon-Router 从完整规模 Multiscale Transformer checkpoint 初始化，不冻结初始化参数；其完整规模训练使用 batch size 4096、学习率 2×10^{-4}，并额外使用 teacher distillation、router supervision、load balancing 和 expert auxiliary loss，权重见方法章。外部适配基线使用相同的数据和输出协议，但采用各自稳定收敛的吞吐配置。

5.6 评价指标

本文主表只报告由预测概率分布直接定义的五个指标，避免把额外预测集合构造混入模型比较。

分类性能。报告每个 horizon 上的 region top-1 和 top-5 命中率，并在主表中给出四个 horizon 的宏平均结果。状态预测同时输出 airborne/landed 概率；在完整数据集上状态准确率接近 1.0，因此状态指标只保留为完整性报告，不作为区分模型优劣的主依据。

概率质量。区域概率通过 NLL、Brier 分数和 10-bin ECE 评价。对层级模型，评价时使用由粗区域分布与条件子区域分布组合得到的细粒度 H3 概率。

5.7 推理约束

所有模型使用相同的层级概率恢复流程和可达性掩码，粗区域 top-K 与方法章保持一致。主结果不使用额外邻域概率扩散，也不构造额外预测集合；预测集合面积等空间范围评价将在后续采用更独立的协议重新设计。

6 结果

6.1 Q1：完整规模主结果比较

表 1 比较所有模型在 10、30、60 和 120 分钟预测时域上的宏平均结果。

Horizon-Router 的宏平均 top-1/top-5 为 0.6884/0.9710，在所有内部基线和两个外部适配基线中最高。概率质量上，Horizon-Router 的 NLL 为 0.9399，Brier 为 0.4262，也优于最强外部适配

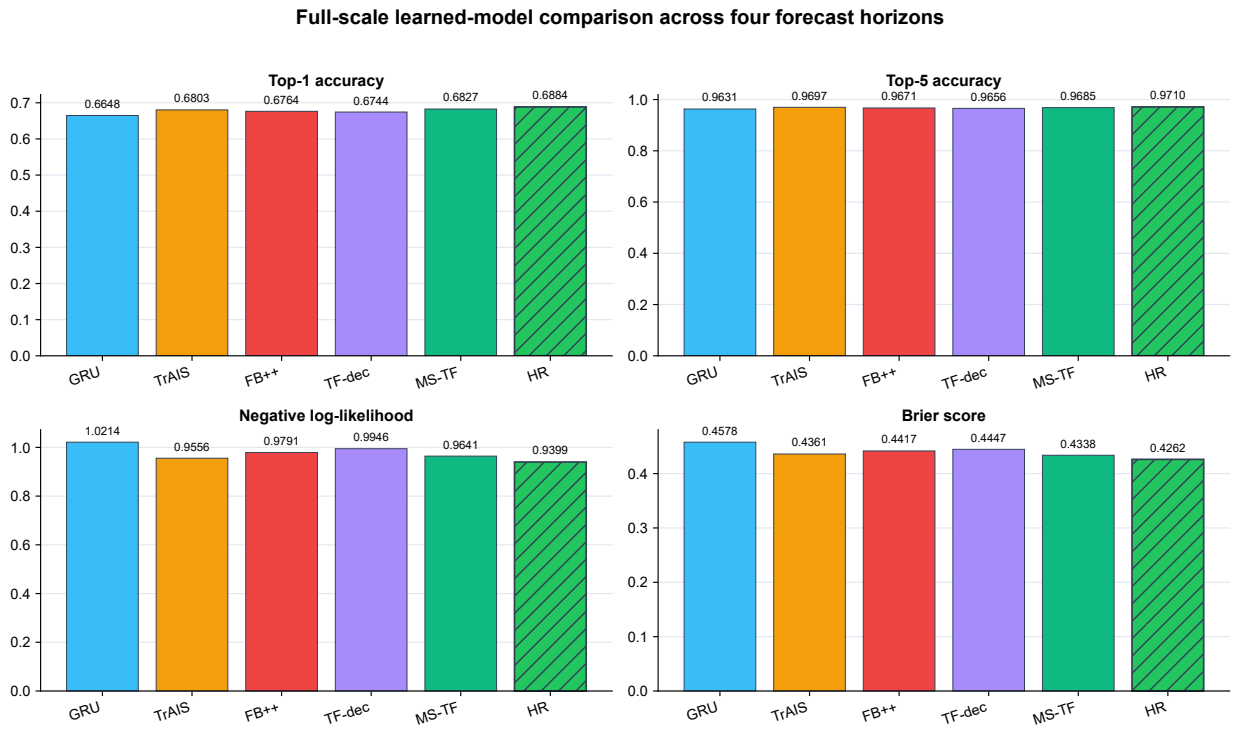


图 2: 完整规模学习模型主结果概览。Markov 基线保留在表 1 中作为经典统计参照；本图只展示神经模型之间的差异。

模型	Top1	Top5	NLL	Brier	ECE
Transformer horizon decoder	0.6744	0.9656	0.9946	0.4447	0.0123
Multiscale Transformer	0.6827	0.9685	0.9641	0.4338	**0.0093**
Horizon-Router	**0.6884**	**0.9710**	**0.9399**	**0.4262**	0.0104

表 2: 内部结构演化比较。Multiscale Transformer 分离多尺度时间编码的收益；Horizon-Router 进一步加入三专家融合和路由训练。

基线的 0.9556 和 0.4361。ECE 方面，外部适配基线的最低值为 0.0086；Horizon-Router 的 ECE 为 0.0104，仍处于较低水平。总体看，最终模型的主要收益来自更好的区域排序和似然/二次评分质量，而不是单一校准指标上的孤立最优。

6.2 Q2：多尺度编码与专家路由的结构收益

表 2 把内部结构演化拆成三步：单尺度 horizon-query、多尺度 horizon-query 和 Horizon-Router。

从 Transformer horizon decoder 到 Multiscale Transformer，top-1 从 0.6744 提升到 0.6827，NLL 从 0.9946 降到 0.9641，Brier 从 0.4447 降到 0.4338，说明显式粗尺度时间分支带来稳定收益。Horizon-Router 在此基础上继续提升到 0.6884 top-1、0.9710 top-5、0.9399 NLL 和 0.4262 Brier。这一结果支持本文的两个方法判断：horizon-query 需要多尺度历史证据，且不同 horizon 还受益于时域级 expert routing。

时域	ΔTop1	ΔTop5	ΔNLL	ΔBrier	ΔECE
10m	+0.0252	+0.0052	-0.0772	-0.0359	+0.0025
30m	+0.0304	+0.0122	-0.1169	-0.0426	-0.0306
60m	+0.0147	+0.0028	-0.0449	-0.0199	+0.0042
120m	+0.0242	+0.0114	-0.0869	-0.0282	-0.0067

表 3: Horizon-Router 相较层级 GRU 基线的逐时域差值。对于 top-k，正值更好；对于 NLL、Brier 和 ECE，负值更好。

相较层级 GRU，Horizon-Router 在四个 horizon 上均改善 top-k 与概率指标。表 3 给出逐时域差值；提升在 30 和 120 分钟上尤其明显，分别带来 +0.0304 和 +0.0242 的 top-1 增益。

6.3 Q3：路由训练机制的完整规模消融

本节预留给完整规模训练消融。需要补充三组共享数据划分、初始化 checkpoint、训练预算和评价协议的 Horizon-Router 变体：router only、router + horizon-wise distillation，以及 router + horizon-wise distillation + loss-aware routing regularization。当前稿件不使用开发子集诊断结果作为主文证据；待三组完整规模实验完成后，本节应报告与表 1 相同的五个指标，并只讨论蒸馏和路由正则是否带来可复现的 full-scale 增益。

7 讨论与限制

本文的主要结果不是简单证明 Transformer 优于 GRU，而是说明多时域区域航空预测需要两层时域适配。第一层是多尺度 horizon-query 编码：不同预测提前量应分别读取细尺度和粗尺度历史证据。第二层是 Horizon-Router：当短时局部机动、粗尺度稳定趋势和完整历史多尺度趋势同时存在时，时域级 router 可以为不同 horizon 选择更合适的 expert 组合。

区域化表述本身也很重要。在开放运行数据上，尤其是 60 到 120 分钟预测时域，长距离点式轨迹回归容易制造并不可靠的精确感。H3 区域概率把不确定性显式化，使 top-k 排序、NLL、Brier 和 ECE 能够在同一离散概率空间中比较。本文本轮主结果刻意不报告预测集合面积，以免把额外集合构造与模型概率质量混在一起；预测集合大小、空间面积和覆盖风险之间的关系需要在后续用更独立的协议评价。

当前论文也有明确边界。首先，虽然 H3 表示在空间上是通用的，但本文实验使用的是 ADRR 中一个月商业航班运行档案，不应被解读为已经覆盖所有航空运行场景。更广泛的跨区域、跨季节和跨数据源验证仍然需要后续实验。

其次，当前模型保留 gap indicator，但没有显式建模缺失观测造成的不确定性。模型也不是 GRU-D、连续时间潜变量动力学或 conformal regional prediction 意义上的缺失感知预测器。这一部分应作为下一阶段工作，而不是当前论文的隐含贡献。

第三，路由训练机制仍需要完整规模逐项消融。当前 full-scale 证据主要体现在最终 Horizon-

Router 相较 Multiscale Transformer 的提升；若要把 horizon-wise distillation、router supervision、load balancing 和 expert auxiliary loss 分别作为强因果贡献，还需要在相同数据划分和训练预算下补齐 router only、router + horizon-wise distillation、router + horizon-wise distillation + loss-aware routing regularization 三组实验。

最后，外部航空基线受任务不匹配限制较大。现有许多文献处理短时坐标预测、终端区交互，或依赖当前 ADRR 派生 artifact 中不可用的密集上下文输入。本文因此采用适配后的 TrAISformer-H3 和 FlightBERT++-H3 作为强基线，并明确固定数据、输出头和评价协议。该选择保证了同表比较的可解释性，但也意味着本文不是对原论文任务的逐字复现。

8 结论

本文基于 ADRR 派生开放航空数据，研究面向未来空域需求感知的多时域层级区域航空轨迹概率预测。围绕这一任务，本文提出多尺度 horizon-query 编码器和 Horizon-Router 单模型：前者让每个 horizon 同时读取细尺度与粗尺度历史证据，后者用 global、coarse-stable 和 local-causal 三个 expert 以及 horizon-level router 建模不同提前量的证据需求。训练上，本文引入基于 expert loss 的路由监督、活跃 expert mask、负载均衡、辅助 expert 监督和 horizon-wise distillation，以稳定路由模型训练。

完整规模实验显示，Horizon-Router 相较 Markov、层级 GRU、Transformer horizon decoder、Multiscale Transformer、TrAISformer-H3 和 FlightBERT++-H3，在 top-1/top-5、NLL 和 Brier 分数上取得更好的整体结果，并保持较低 ECE。路由训练机制的逐项效果仍需要后续完整规模消融进一步确认。

总体而言，实验结果支持将长时航空预测表述为层级 H3 区域概率建模问题。下一步更值得推进的是缺失观测下的不确定性建模、完整规模逐项路由消融、预测集合面积协议，以及跨数据源的区域需求聚合验证。

数据可用性与可复现性

本文实验使用一个月的飞行轨迹，数据来源于 EUROCONTROL Aviation Data Repository for Research（ADRR）[9]。EUROCONTROL 按其使用条款向研究和开发用途提供 ADRR 访问，但原始数据不能由本文作者公开再分发。为支持可复现性，项目仓库包含用于标准化 ADRR 数据的端到端预处理脚本、所有报告实验的配置文件、所有比较方法的模型实现、实验日志和评估摘要，以及用于重建开发子集和重新运行完整实验的脚本。

参考文献

[1] Federal Aviation Administration. Trajectory based operations. https://www.faa.gov/air_traffic/technology/tbo/, 2026. Accessed 2026-06-06.

[2] International Civil Aviation Organization. Global air navigation plan. https://www4.icao.int/ganpportal/, 2026. Accessed 2026-06-06.

[3] Ronald Reisman, James Murphy, Patrick Krolak, and Richard Wright. Modeling tactical trajectory accuracy effects on traffic flow management operations. In *7th AIAA ATIO Conference*. American Institute of Aeronautics and Astronautics, 2007. doi: 10.2514/6.2007-7860. URL https://doi.org/10.2514/6.2007-7860.

[4] Joey Mercer, Nancy Bienert, Ashley Gomez, Sarah Hunt, Joshua M. Kraut, Lynne Martin, Susan Morey, Steven Green, Thomas Prevot, and Minghong G. Wu. The impact of trajectory prediction uncertainty on air traffic controller performance and acceptability. In *2013 Aviation Technology, Integration, and Operations Conference*. American Institute of Aeronautics and Astronautics, 2013. doi: 10.2514/6.2013-4320. URL https://doi.org/10.2514/6.2013-4320.

[5] J. Chen, L. Chen, and D. Sun. Air traffic flow management under uncertainty using chance-constrained optimization. *Transportation Research Part B: Methodological*, 102:124–141, 2017. doi: 10.1016/j.trb.2017.05.014. URL https://doi.org/10.1016/j.trb.2017.05.014.

[6] Juan Nunez-Portillo, Alfonso Valenzuela, Antonio Franco, and Damián Rivas. Predicting air traffic congestion under uncertain adverse weather. *Aerospace*, 11(3):240, 2024. doi: 10.3390/aerospace11030240. URL https://doi.org/10.3390/aerospace11030240.

[7] Matthias Schäfer, Martin Strohmeier, Vincent Lenders, Ivan Martinovic, and Matthias Wilhelm. Bringing up opensky: A large-scale ADS-B sensor network for research. In *Proceedings of the 13th International Symposium on Information Processing in Sensor Networks*, pages 83–94. IEEE, 2014. doi: 10.1109/IPSN.2014.6846743. URL https://doi.org/10.1109/IPSN.2014.6846743.

[8] Martin Strohmeier, Xavier Olive, Jannis Lübbe, Matthias Schäfer, and Vincent Lenders. Crowdsourced air traffic data from the OpenSky network 2019–2020. *Earth System Science Data*, 13:357–366, 2021. doi: 10.5194/essd-13-357-2021. URL https://doi.org/10.5194/essd-13-357-2021.

[9] EUROCONTROL. Aviation data repository for research (ADRR). https://www.eurocontrol.int/dashboard/aviation-data-research, 2025. Accessed 2026-05-21.

[10] Peiyan Jia, Huiping Chen, Lei Zhang, and Daojun Han. Attention-LSTM based prediction model for aircraft 4-D trajectory. *Scientific Reports*, 12, 2022. doi: 10.1038/s41598-022-19794-1. URL https://doi.org/10.1038/s41598-022-19794-1.

[11] Lan Ma, Xianran Meng, and Zhijun Wu. Data-driven 4D trajectory prediction model using attention-TCN-GRU. *Aerospace*, 11(4):313, 2024. doi: 10.3390/aerospace11040313. URL https://doi.org/10.3390/aerospace11040313.

[12] Zheng Zhang, Dongyue Guo, Shizhong Zhou, Jianwei Zhang, and Yi Lin. Flight trajectory prediction enabled by time-frequency wavelet transform. *Nature Communications*, 14:5258, 2023. doi: 10.1038/s41467-023-40903-9. URL https://doi.org/10.1038/s41467-023-40903-9.

[13] Dongyue Guo, Zheng Zhang, Jiayi Liu, Jianwei Zhang, and Yi Lin. Multi-horizon flight trajectory prediction enabled by time-frequency wavelet transform. *Nature Communications*, 17:633, 2026. doi: 10.1038/s41467-025-67399-9. URL https://doi.org/10.1038/s41467-025-67399-9.

[14] Dongyue Guo, Zheng Zhang, Zhen Yan, Jianwei Zhang, and Yi Lin. FlightBERT++: A non-autoregressive multi-horizon flight trajectory prediction framework. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pages 127–134, 2024. doi: 10.1609/aaai.v38i1.27763. URL https://doi.org/10.1609/aaai.v38i1.27763.

[15] Kevin Sahr, Denis White, and A. Jon Kimerling. Geodesic discrete global grid systems. *Cartography and Geographic Information Science*, 30(2):121–134, 2003. doi: 10.1559/152304003100011090. URL https://doi.org/10.1559/152304003100011090.

[16] H3 Contributors. H3 core library overview. https://h3geo.org/docs/core-library/overview, 2025. Accessed 2026-05-21.

[17] Tilmann Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007. doi: 10.1198/016214506000001437. URL https://doi.org/10.1198/016214506000001437.

[18] Glenn W. Brier. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1):1–3, 1950. doi: 10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2. URL https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2.

[19] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *PMLR*, pages 1321–1330, 2017. URL https://proceedings.mlr.press/v70/guo17a.html.

[20] Bryan Lim, Sercan Ö. Arik, Nicolas Loeff, and Tomas Pfister. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4):1748–1764, 2021. doi: 10.1016/j.ijforecast.2021.03.012. URL https://doi.org/10.1016/j.ijforecast.2021.03.012.

[21] Carson Eisenach, Yagna Patel, and Dhruv Madeka. MQTransformer: Multi-horizon forecasts with context dependent and feedback-aware attention, 2020. URL https://arxiv.org/abs/2009.14799.

[22] Robert A. Jacobs, Michael I. Jordan, Steven J. Nowlan, and Geoffrey E. Hinton. Adaptive mixtures of local experts. *Neural Computation*, 3(1):79–87, 1991. doi: 10.1162/neco.1991.3.1.79. URL https://doi.org/10.1162/neco.1991.3.1.79.

[23] Noam Shazeer, Azalia Mirhoseini, Krzysztof Maziarz, Andy Davis, Quoc Le, Geoffrey Hinton, and Jeff Dean. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer, 2017. URL https://arxiv.org/abs/1701.06538.

[24] William Fedus, Barret Zoph, and Noam Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. *Journal of Machine Learning Research*, 23(120):1–39, 2022. URL https://jmlr.org/papers/v23/21-0998.html.

[25] Cristian Bucila, Rich Caruana, and Alexandru Niculescu-Mizil. Model compression. In *Proceedings of the 12th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, KDD '06, pages 535–541. ACM, 2006. doi: 10.1145/1150402.1150464. URL https://doi.org/10.1145/1150402.1150464.

[26] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network, 2015. URL https://arxiv.org/abs/1503.02531.

[27] Tommaso Furlanello, Zachary C. Lipton, Michael Tschannen, Laurent Itti, and Anima Anandkumar. Born again neural networks. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *PMLR*, pages 1607–1616, 2018. URL https://proceedings.mlr.press/v80/furlanello18a.html.

[28] Gonzalo Tobaruela, Peter Fransen, Wolfgang Schuster, Washington Y. Ochieng, and Arnab Majumdar. Air traffic predictability framework: Development, performance evaluation and application. *Journal of Air Transport Management*, 39:48–58, 2014. doi: 10.1016/j.jairtraman.2014.04.001. URL https://doi.org/10.1016/j.jairtraman.2014.04.001.

[29] Weili Zeng, Xiao Chu, Zhengfeng Xu, Yan Liu, and Zhibin Quan. Aircraft 4D trajectory prediction in civil aviation: A review. *Aerospace*, 9(2):91, 2022. doi: 10.3390/aerospace9020091. URL https://doi.org/10.3390/aerospace9020091.

[30] NaeJoung Kwak and ByoungYup Lee. The evolution and taxonomy of deep learning models for aircraft trajectory prediction: A review of performance and future directions. *Applied Sciences*, 15(19):10739, 2025. doi: 10.3390/app151910739. URL https://doi.org/10.3390/app151910739.

[31] Youyou Li, Yuxiang Fang, and Teng Long. Noise robust aircraft trajectory prediction via autoregressive transformers with hybrid positional encoding. *Scientific Reports*, 15, 2025. doi: 10.1038/s41598-025-96512-7. URL https://doi.org/10.1038/s41598-025-96512-7.

[32] Ruiyan Shan, Liquan Dong, Kang Li, and Lianqing Dong. A deep learning framework for predicting aircraft trajectories from sparse satellite observations. *Scientific Reports*, 15, 2025. doi: 10.1038/s41598-025-27064-z. URL https://doi.org/10.1038/s41598-025-27064-z.

[33] Martin Strohmeier. Research usage and social impact of crowdsourced air traffic data. In *8th OpenSky Symposium 2020*, OpenSky 2020, page 1. MDPI, 2020. doi: 10.3390/proceedings2020059001. URL https://doi.org/10.3390/proceedings2020059001.

[34] Gano Chatterji, Banavar Sridhar, and Douglas Kim. Analysis of ETMS data quality for traffic flow management decisions. In *AIAA Guidance, Navigation, and Control Conference and*

Exhibit. American Institute of Aeronautics and Astronautics, 2003. doi: 10.2514/6.2003-5626. URL https://doi.org/10.2514/6.2003-5626.

[35] Jimmy Krozel. Intent inference for free flight aircraft. In *AIAA Guidance, Navigation, and Control Conference and Exhibit*. American Institute of Aeronautics and Astronautics, 2000. doi: 10.2514/6.2000-4479. URL https://doi.org/10.2514/6.2000-4479.

[36] Pek Hui Foo, Gee Wah Ng, Khin Hua Ng, and Rong Yang. Application of intent inference for surveillance and conformance monitoring to aid human cognition. In *2007 10th International Conference on Information Fusion*, pages 1–8, 2007. doi: 10.1109/ICIF.2007.4408081. URL https://doi.org/10.1109/ICIF.2007.4408081.

[37] Yang Yang, Jun Zhang, and Kai quan Cai. Terminal-area aircraft intent inference approach based on online trajectory clustering. *The Scientific World Journal*, 2015, 2015. doi: 10.1155/2015/671360. URL https://doi.org/10.1155/2015/671360.

[38] Hyeonwoong Lee and Hak-Tae Lee. Extracting flight plans from recorded ADS-B trajectories. *International Journal of Aeronautical and Space Sciences*, 24(2):581–589, 2022. doi: 10.1007/s42405-022-00539-3. URL https://doi.org/10.1007/s42405-022-00539-3.

[39] Duong Nguyen and Ronan Fablet. TrAISformer: A transformer network with sparse augmented data representation and cross entropy loss for AIS-based vessel trajectory prediction, 2021. URL https://arxiv.org/abs/2109.03958.