基于层级 H3 预测与多尺度 Horizon-Query Transformer 的大规模多时域区域航空轨迹预测

作者信息待补充

摘要

开放飞行监视数据和运行档案正在把航空轨迹预测从小样本、局部空域问题推向大规模、可复现建模，但现有研究仍以短时坐标回归和局部四维轨迹外推为主。对于开放运行数据上的长时域预测，这类设定并不总是最合适：未来航迹本身具有多模态性，观测覆盖与数据质量也并不均匀，因而比单一点位更需要可校准的区域概率表达。本文研究多时域区域航空轨迹预测问题。基于 ADRR 派生的一个月商业航班轨迹数据，我们构建了 20,712,602 个预测窗口；给定按 5 分钟重采样的 30 分钟历史轨迹，模型需要同时预测未来 10、30、60 和 120 分钟的 H3 区域概率分布。为此，本文提出多尺度 horizon-query Transformer，并将其与层级式 coarse-to-fine H3 解码器结合：细粒度历史分支保留局部机动信息，粗粒度池化分支提取较长时间尺度上下文，不同预测时域通过可学习 query 从编码状态中检索相关信息。除 top-k 区域命中率外，本文还从负对数似然、Brier 分数、期望校准误差以及候选区域覆盖率与面积等角度评估模型。与层级 GRU 基线相比，所提方法将宏平均 top-1/top-3/top-5 准确率从 0.6648/0.9076/0.9631 提升到 0.6827/0.9174/0.9685，NLL 从 1.0214 降至 0.9641，Brier 分数从 0.4578 降至 0.4338，ECE 从 0.0180 降至 0.0093；与经典 Markov 基线以及适配后的强 Transformer 基线相比，本文方法在长时域 top-1、概率校准和候选区域紧致性上表现更均衡。结果表明，在开放大规模航空轨迹数据上，层级 H3 区域概率预测能够为长时域轨迹建模提供一种比点式外推更稳健、也更便于评估的建模路径。

关键词：航空轨迹预测；H3 空间索引；多时域预测；概率预测；Transformer；校准性

1 引言

开放飞行监视网络和研究档案正在持续改变航空数据分析的研究条件。OpenSky Network 证明了众包 ADS-B 传感网络可以长期支撑大规模可复现研究 [1]，后续发布的 OpenSky 2019–2020 数据集又进一步说明，开放飞行数据已经能够覆盖大范围、长时间跨度的民航运行 [2]。EUROCONTROL 的 Aviation Data Repository for Research（ADRR）则向研究和开发提供了更结构化的商业航班轨迹与运行信息档案 [3]。在这样的数据条件下，航空轨迹预测不再只能围绕少量航班、单一机场或封闭基准展开，而可以被重新表述为一个面向开放数据、长时域和可复现实验的问题。

但数据规模的变化并不自动等于问题设定的变化。已有航空轨迹预测研究大多仍以连续坐标或四维轨迹回归为中心，例如 Attention-LSTM 四维轨迹预测模型 [4]、基于时频小波变换的轨迹预测方法 [5]，以及更近期的直接多时域 FlightBERT++ 框架 [6]。另一些工作关注噪声 ADS-B 观测和稀疏卫星观测等更困难的数据条件 [7, 8]。这些方法说明，更强的时间编码和多时域建模确实能够提升点式轨迹预测性能；但当研究对象变成开放运行档案上的 60–120 分钟预测时，单一路径坐标外推并不总是最合适的输出形式。

原因在于，开放运行数据上的长时域未来本身具有更强的不确定性和多模态性。相同的历史片段可能对应不同航路选择、不同阶段的爬升或下降过程，甚至不同的速度控制策略。此时，把模型能力集中在“给出一条最像真的未来轨迹”上，往往既不利于刻画不确定性，也不利于后续运行解释。对于战略交通态势感知、监视韧性分析、区域级流量推理和候选航路筛选而言，更自然的问题表述是：在给定预测提前量时，航空器未来最可能出现在哪些区域上，以及这些区域的概率是否可信。

因此，本文研究*多时域区域航空轨迹预测*。与传统点预测不同，本文不是直接回归未来经纬度序列，而是在多个预测提前量上输出未来 H3 区域概率分布。这样的任务表述有三点实际意义。第一，它显式承认并表达长时域预测的不确定性，而不是把所有不确定性压缩进一条点轨迹。第二，它与开放轨迹档案的空间分辨率和运行多样性更匹配，避免把建模目标过度绑定到精确点位误差。第三，它天然支持面向概率质量和区域效率的评价，包括负对数似然、Brier 分数、期望校准误差，以及候选区域覆盖率、候选 cell 数量和候选面积。

本文工作的技术起点是一个已有的层级 H3 区域预测器，其核心为 GRU 历史编码器和 coarse-to-fine 解码头。我们保留这一层级空间输出框架，因为它已经能够把区域概率预测与父子层级约束、候选区域生成和可解释评估统一起来。本文进一步关注的是时间建模问题：在大规模开放航空轨迹上，什么样的时间结构更适合多时域概率区域预测？我们的实验表明，关键不在于简单地把编码器做得更深，而在于让不同预测时域能够从历史序列中读取不同的信息子集。

基于这一判断，本文提出*多尺度 horizon-query Transformer*。模型由细粒度历史编码分支、粗粒度池化历史编码分支以及面向不同预测时域的可学习 query 组成；不同 horizon 通过 query attention 从编码状态中检索与本时域最相关的历史上下文，而后接入与基线兼容的层级 H3 解码器。这样的设计使时间建模改进可以在不破坏原有输出协议的前提下被单独评估，也便于与 Markov 基线、层级 GRU 基线、结构消融模型以及适配后的外部基线进行公平比较。

本文主要贡献如下：

1. 基于 ADRR 派生的一个月商业航班轨迹数据，将大规模开放运行档案上的多时域航空预测问题形式化为层级 H3 概率区域预测任务，并给出可复现的数据划分与评估协议。
2. 提出多尺度 horizon-query Transformer，在保持 coarse-to-fine H3 输出结构不变的前提下，显式建模不同预测时域对历史上下文的差异化需求，并在完整数据集上稳定提升区域准确率与概率质量。
3. 建立兼顾精度、概率质量和区域效率的评估视角，同时报告 top-k 命中率、NLL、Brier 分数、ECE、候选覆盖率、候选 cell 数量与候选面积，而不是只依赖单一命中率指标。
4. 给出与经典 Markov 基线、层级 GRU 基线、结构消融模型以及适配后的强外部基线的比较，并通过 H3 邻域 refinement 消融说明候选召回与概率校准之间存在明确权衡。

2 相关工作

2.1 航空轨迹点预测与多时域航空预测

航空轨迹预测的主流文献长期围绕连续点位或四维轨迹回归展开。Attention-LSTM 模型将注意力机制引入四维轨迹预测，以改善对历史关键状态的利用 [4]；Attention-TCN-GRU 模型则结合时序卷积、循环单元和注意力模块进行数据驱动的四维轨迹预测 [9]。这类方法说明，历史片段中的不同时间步对未来轨迹并非同等重要。除循环网络外，近期航空文献也开始引入更强的时频与

Transformer 结构。例如，WTFTP 利用时频小波表示建模轨迹中的全局与局部模式 [5]，其后续工作 WTFTP+ 进一步将问题扩展到直接多时域预测 [10]；FlightBERT++ 则明确采用非自回归广义 encoder-decoder 框架，配合 horizon-aware context generator 与 differential-prompted decoder，直接输出多个预测提前量上的飞行状态 [6]。与此同时，也有研究开始面向更复杂的数据条件，处理噪声 ADS-B 观测或稀疏卫星观测场景 [7, 8]。

这些工作共同推动了航空轨迹预测从单步外推走向更复杂的序列建模，但它们绝大多数仍以连续坐标误差为主要目标。相比之下，本文关注的是开放运行档案上的长时域区域概率预测：输出空间从连续点轨迹转为层级 H3 区域分布，评价目标也从点误差扩展到概率质量和候选区域效率。

2.2 多时域预测与 horizon-aware 解码

从更一般的序列预测文献来看，多时域预测的核心难点并不只是“预测得更远”，而在于不同 horizon 往往依赖历史中的不同信息。Temporal Fusion Transformer 将局部时序处理、门控结构与注意力机制结合，用于可解释的多时域预测 [11]。MQTransformer 则更直接地指出，若所有预测时域都共享同一个压缩上下文，模型容易受到信息瓶颈影响；为此，该工作引入依赖上下文的 decoder-encoder attention，使不同 horizon 可以读取不同的历史表示 [12]。在离散轨迹建模方向，TrAISformer 将离散空间表示与 Transformer 结合，用于 AIS 航迹预测，说明基于离散空间支撑的序列建模可以成为坐标回归之外的另一条路线 [13]。

本文的时间结构设计直接受到这类工作启发。我们并不让全部预测时域共享单个历史摘要向量，而是为每个 horizon 分配独立的可学习 query，让模型从历史编码状态中提取与该时域最相关的信息。与通用时间序列预测器不同的是，本文把这种 horizon-aware 解码嵌入到了层级 H3 航空区域预测框架中，并与 coarse-to-fine 输出头保持兼容。

2.3 概率预测、校准与候选区域评估

一旦输出从“单点轨迹”转向“区域概率分布”，评价问题就不再只是命中率问题。Gneiting 和 Raftery 系统讨论了严格适定评分规则，指出概率预测不仅需要高分辨率，还需要在校准约束下保持足够尖锐 [14]。Brier 分数作为概率预测中的经典二次评分规则，长期被用于衡量类别事件预测的整体质量 [15]。在深度学习背景下，Guo 等人进一步表明，即使现代神经网络在准确率上表现良好，也可能存在明显误校准 [16]。

这类结论对于航空区域预测尤其重要。一个模型可以通过把概率质量摊到更大的空间支持上来提高 top-k 或候选召回，但这并不意味着它给出的概率是可信的，也不意味着候选区域在运行上可用。因此，本文除了报告 top-k 区域命中率外，还同时报告 NLL、Brier 分数和 ECE，并显式衡量候选覆盖率、候选 cell 数量和候选面积。这样的评估方式有助于区分“真正学到了更好的概率分布”与“仅仅扩大了候选区域”这两类模型。

2.4 开放飞行数据、离散空间建模与层级网格

本文的问题设定还受到开放飞行数据基础设施和离散空间表示方法的共同影响。OpenSky 的原始传感网络与后续开放数据发布，使得面向真实运行流量的大规模研究成为可能 [1, 2]；ADRR 则提供了更适合研究与开发的结构化飞行档案 [3]。在空间表示方面，离散全球网格系统为多分辨率区域推理提供了统一支撑 [17]，而 H3 进一步给出了工程上成熟的层级六边形索引和邻域操作

接口 [18]。本文正是在这一背景下，把多时域航空预测从连续坐标回归改写为层级 H3 概率区域预测，并将区域概率、层级解码和候选区域评估纳入同一实验协议中。

3 问题定义

设历史窗口为

$$X = \{z_1, z_2, \ldots, z_T\}, \qquad T = 6, \tag{1}$$

其中 $T = 6$ 对应 30 分钟历史在 5 分钟采样间隔下的 6 个重采样时刻。每个时间步 $z_t = (r_t, p_t, u_t, m_t)$ 包含四类输入：输入分辨率 H3 区域 id r_t、其父层 H3 区域 id p_t、数值特征向量 $u_t \in \mathbb{R}^{18}$，以及 mask 向量 $m_t \in \{0,1\}^2$。本文沿用项目既有特征构造流程：数值特征覆盖位置正余弦编码、位移与距离增量、航迹方向、区域切换、飞行高度、速度、航向、垂直速度、时间间隔和地面状态；mask 特征为 `observed_flag` 与 `gap_flag`。此外，每个样本还包含一个上下文向量 $c \in \mathbb{R}^9$，其中编码了时刻周期、当前位置以及项目既有的目标标识哈希特征。

预测时域集合记为

$$\mathcal{H} = \{10, 30, 60, 120\} \text{ minutes}. \tag{2}$$

对每个时域 $h_j \in \mathcal{H}$，模型需要同时输出：（1）粗粒度 H3 区域标签 $y_j^{(c)}$；（2）在粗区域条件下的细粒度子区域标签 $y_j^{(f)}$；（3）状态标签 $s_j \in \{\text{airborne}, \text{landed}\}$。在本文的完整实验中，细粒度目标分辨率为 $[3, 3, 2, 2]$，对应粗粒度分辨率为 $[2, 2, 1, 1]$。因此，短时预测保持更细的空间粒度，而 60 和 120 分钟时域使用更粗的空间支撑以匹配增长的不确定性。

细粒度区域预测被写成层级条件分解：

$$p(y_j^{(c)}, y_j^{(f)}, s_j \mid X, c, h_j) = p(s_j \mid X, c, h_j)\, p(y_j^{(c)} \mid X, c, h_j)\, p(y_j^{(f)} \mid y_j^{(c)}, X, c, h_j). \tag{3}$$

这种分解与 H3 的父子层级一致，也使模型能够在较大输出空间上保持可训练的类别规模。对于某些样本，较长时域的未来标签可能因 mission 截断而不可用。项目实现中为每个时域维护有效性掩码 $v_j \in \{0,1\}$，仅在 $v_j = 1$ 时累计损失和评价指标。

训练目标由粗区域分类、细区域分类和状态分类三部分构成。记 $\mathcal{V}$ 为有效 horizon 集合，则单样本损失写为

$$\mathcal{L} = \frac{1}{|\mathcal{V}|} \sum_{j \in \mathcal{V}} \left[\ell_{\text{coarse}}^{(j)} + \ell_{\text{child}}^{(j)} + \ell_{\text{status}}^{(j)} \right] + \lambda_{\text{cons}} \mathcal{L}_{\text{cons}}, \tag{4}$$

其中三项基本损失均为交叉熵；$\ell_{\text{child}}^{(j)}$ 仅在对应父区域下的子类标签有效时计算；$\mathcal{L}_{\text{cons}}$ 是可选的相邻 horizon 解码特征一致性正则。最终报告模型中 $\lambda_{\text{cons}} = 0$，即不启用该正则项。

给定每个时域上的细粒度区域概率 π_j 后，本文同时评价分类性能、概率质量和候选区域效率。区域分类指标包括 top-1/top-3/top-5 命中率；概率质量指标包括负对数似然（NLL）、Brier 分数和期望校准误差（ECE）。为评价候选区域，本文在每个 horizon 上按概率从高到低选择细粒度 cell，直到累计概率质量达到阈值 $\tau_j = 0.8$ 或达到最大 cell 预算 B_j，其中

$$B = [24, 18, 18, 24]. \tag{5}$$

随后将被选中的 1-ring 邻接 cell 合并为连通候选组件，并按组件概率质量排序。基于这一构造，本文报告：（1）候选组件并集是否覆盖真实目标 cell 的 *candidate union cover*；（2）候选并集的平均 cell 数量与平均面积；（3）在固定 cell 预算下的覆盖率和面积。这样的定义使“更高召回”与“更大空间扩张”能够被明确区分，也使不同模型的概率分布是否既准确又紧凑成为可检验问题。

4 方法

4.1 总体思路

本文方法建立在一个统一的层级 H3 预测框架上：所有神经模型都使用相同的输入张量格式、相同的粗到细输出头、相同的层级损失定义以及相同的评价协议。这样做有两个目的。第一，它把研究重点集中在*时间建模结构*本身，而不是把性能变化混杂到输出空间或评价口径中。第二，它使内部模型演化和外部适配基线都能在同一 H3 区域预测任务下公平比较；不同模型在训练时只允许采用各自稳定收敛所需的超参数设置。

整体流程如下。原始飞行记录先经 mission 切分和 5 分钟重采样，随后被编码为历史区域 token、父层区域 token、数值运动特征、mask 特征和上下文特征。时间编码模块将历史序列映射为针对不同 horizon 的解码特征；层级输出头再分别预测粗区域、状态以及条件细区域分布。推理阶段，粗区域分布和条件子区域分布被组合成细粒度 H3 概率，随后再进入 reachability filtering 和候选区域生成模块。

4.2 输入表示与时间有效掩码

对每个时间步 $z_t = (r_t, p_t, u_t, m_t)$，模型分别学习输入区域 embedding、父层区域 embedding，并将数值特征和 mask 特征线性投影到同一隐空间。设嵌入和投影后的时间步表示为

$$\tilde{z}_t = [E_r(r_t); E_p(p_t); W_u u_t; W_m m_t]. \tag{6}$$

其中 $E_r(\cdot)$ 和 $E_p(\cdot)$ 分别是输入 H3 区域与父层区域 embedding 表，W_u 和 W_m 为数值与 mask 投影矩阵。样本级上下文向量 c 通过单独线性层投影后，与时间编码摘要拼接。

项目实现没有简单地把全部填充值都视为有效观测，而是根据 `observed_flag`、`gap_flag` 和未知区域 token 共同构造时间有效掩码。只有在时间步不是“由缺口补齐且区域未知”的情况下，该时间步才被视为有效。这一掩码被所有 attention 或 pooling 模块共享，用于抑制填充片段对历史摘要的污染。

4.3 共享的层级 H3 输出头

所有层级模型共享同一输出协议。对每个预测时域 h_j，模型先输出粗粒度 logits

$$g_j^{(c)} \in \mathbb{R}^{C_j}, \tag{7}$$

其中 C_j 是该时域对应粗分辨率下的区域类别数；同时输出状态 logits

$$g_j^{(s)} \in \mathbb{R}^2. \tag{8}$$

随后，给定某个粗区域 id $y_j^{(c)}$，模型再通过一个条件子头输出该父区域下的子区域 logits

$$g_j^{(f)}(\cdot \mid y_j^{(c)}) \in \mathbb{R}^{M_j}, \tag{9}$$

其中 M_j 为该时域下预设的最大子类长度。实现上，每个 coarse id 都关联一张合法子类掩码表；超出该父区域实际子类数的 logits 在训练和推理中都被屏蔽为极小值。

训练阶段，子区域交叉熵使用*真值粗区域标签*作为条件，从而稳定地学习父子层级对应关系。推理阶段，模型先从粗区域分布中选取 top-K_j 个父区域，再对每个父区域计算条件子分布，并按

$$p(y_j^{(f)} = c \mid X) = \sum_{y_j^{(c)} \in \mathcal{P}_{K_j}} p(y_j^{(c)} \mid X)\, p(y_j^{(f)} = c \mid y_j^{(c)}, X) \tag{10}$$

把父层概率质量散射回细粒度 H3 cell。未被显式分配的剩余概率质量被写入 unknown 类，以保证每个时域上的细粒度概率和为 1。本文完整实验中使用的父层 top-K 为 $[64, 48, 48, 12]$。

4.4 层级 GRU 基线

项目原始基线是层级 GRU 预测器。它把时间步表示序列 $\{\tilde{z}_t\}_{t=1}^{T}$ 输入多层 GRU 编码器，以最终隐状态 h_T 作为历史摘要，再与上下文投影拼接得到共享特征

$$b = [h_T; W_c c]. \tag{11}$$

对每个 horizon，粗区域头和状态头都直接以这一共享特征为输入，子区域头则在共享特征基础上再拼接父区域 embedding。

这一基线已经具备较强的空间结构先验，但它把所有预测时域都压缩到同一时间摘要 b 上。换言之，10 分钟与 120 分钟预测只能共享同一段时间表征，无法显式访问历史中的不同时段信息。后续实验表明，这正是时间建模的主要瓶颈。

4.5 单尺度 Horizon-Query Transformer

为缓解单一时间摘要带来的信息瓶颈，我们首先把 GRU 时间编码器替换为 horizon-aware Transformer 编码器。具体地，拼接后的时间步表示先被投影到统一隐空间，并加入可学习位置 embedding：

$$H^{(0)} = W_z \tilde{Z} + P. \tag{12}$$

随后，$H^{(0)}$ 进入带时间有效掩码的 Transformer encoder，得到历史编码序列

$$H = \mathrm{Enc}(H^{(0)}). \tag{13}$$

与直接取最后一个时间步不同，编码器输出首先做 masked mean pooling，与上下文投影拼接形成共享基特征 b。

对每个预测时域 h_j，模型维护一个可学习 horizon embedding e_j，并用它与共享特征共同构造 query：

$$q_j = W_q[b; e_j]. \tag{14}$$

该 query 对历史编码序列执行交叉注意力，得到该时域专属的时间摘要

$$\alpha_j = \mathrm{softmax}(q_j H^{\top}), \qquad z_j = \alpha_j H. \tag{15}$$

最终解码特征为

$$d_j = \phi([b; z_j; e_j]), \tag{16}$$

其中 $\phi(\cdot)$ 是一个小型前馈投影模块。与 GRU 基线相比，这一结构允许不同 horizon 从同一段历史中读取不同的信息子集。

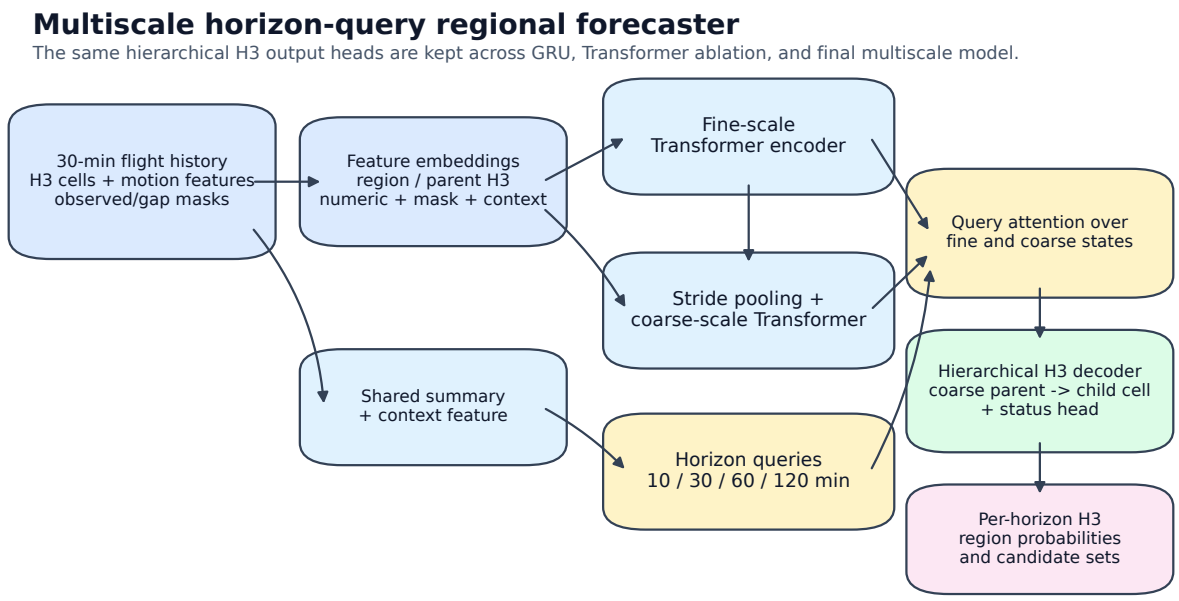


图 1: 所提出的多尺度 horizon-query H3 预测器概览。所有模型变体共享相同的层级 H3 输出头；最终模型在单尺度 horizon-query 结构上增加显式粗尺度时间分支。

4.6 所提出的多尺度 Horizon-Query Transformer

最终模型在单尺度 horizon-query decoder 的基础上，引入显式双时间尺度编码。其核心出发点是：30 分钟历史中既包含局部机动信息，也包含更粗粒度的阶段性变化，而 60–120 分钟预测往往更依赖后者。

具体地，细尺度分支先得到历史编码序列 $H^{(f)}$。然后按照 stride $= 2$ 对细尺度序列做带掩码的局部均值池化，在本文的 6 步历史设置下得到 3 步粗尺度序列，再通过额外的单层 Transformer encoder 得到

$$H^{(c)} = \mathrm{Enc}_{\mathrm{coarse}}(\mathrm{Pool}(H^{(f)})). \tag{17}$$

同一个 horizon query q_j 分别对细尺度和粗尺度序列进行注意力检索：

$$\alpha_j^{(f)} = \mathrm{softmax}(q_j {H^{(f)}}^\top), \qquad \alpha_j^{(c)} = \mathrm{softmax}(q_j {H^{(c)}}^\top), \tag{18}$$

$$z_j^{(f)} = \alpha_j^{(f)} H^{(f)}, \qquad z_j^{(c)} = \alpha_j^{(c)} H^{(c)}. \tag{19}$$

最终的 horizon 专属解码特征写为

$$d_j = \phi_{\mathrm{ms}}([b; z_j^{(f)}; z_j^{(c)}; e_j]). \tag{20}$$

其中 ϕ_{ms} 是多尺度特征融合模块。所有粗区域头、状态头和条件子区域头都共享这一解码协议，只是输入的 d_j 由单尺度或多尺度时间编码器决定。

4.7 训练目标与可选正则

在层级模型中，粗区域、子区域和状态三项损失都采用交叉熵，并仅在有效标签上累计。设 $\mathcal{V}$ 为可用 horizon 集合，则一个 mini-batch 的层级损失可写为

$$\mathcal{L}_{\text{hier}} = \frac{1}{|\mathcal{V}|} \sum_{j \in \mathcal{V}} \left(\mathcal{L}^{(j)}_{\text{coarse}} + \mathcal{L}^{(j)}_{\text{child}} + \mathcal{L}^{(j)}_{\text{status}} \right). \tag{21}$$

项目中还实现了一个可选的相邻 horizon 解码特征一致性项，即对 d_j 与 d_{j+1} 的均方差施加惩罚，并按相邻 horizon 间隔做缩放。但在 devsplit 和 full-scale 实验中，该项未带来稳定收益，因此最终模型设置为 $\lambda_{\text{cons}} = 0$。

4.8 推理时后处理：Reachability 与 H3 Refinement

完整推理流程包含两类后处理，但它们与主模型分开评估。第一类是 reachability filter。对每个 horizon，系统根据当前 H3 cell 中心与候选目标 cell 中心之间的球面距离构造可达性掩码；若某目标 cell 的距离超过

$$d_{\max}(h_j) = v_{\max} \cdot 1.852 \cdot \frac{h_j}{60} + \Delta, \tag{22}$$

则其概率被置零并重新归一化。本文默认采用 $v_{\max} = 750$ knots、$\Delta = 250$ km。第二类是 H3 neighbor refinement，它在评价阶段把部分细粒度概率质量按系数 α 扩散到局部 H3 邻居。由于它会显著改变概率校准，本文只把它作为消融分析，不把它计入最终主方法。

5 实验设置

5.1 数据与划分协议

实验使用基于 ADRR 构建的 2024 年 3 月商业航班轨迹档案。按照项目既有流程，原始记录先按 90 分钟时间缺口切分为 mission，并对不超过 30 分钟的局部缺口做规则化处理；随后轨迹被重采样到 5 分钟时间网格，并构造区域、数值、mask 和上下文特征。为避免过短或信息不足的片段进入训练集，本文要求有效轨迹段至少包含 8 个重采样点。

处理完成后，数据集中共有 20,712,602 个预测窗口，其中训练集、验证集和测试集分别包含 14,505,637、3,108,933 和 3,098,032 个窗口。与很多窗口级随机切分方案不同，本文按航空器 id 进行 train/val/test 划分，从而尽量避免同一航空器的重复运行模式同时出现在训练和测试中。由于研究对象是开放运行档案而非单机场局部场景，这样的划分更接近真实部署时面对未见航空器或未见轨迹片段的情形。

5.2 时间与空间协议

所有模型统一使用 30 分钟历史、5 分钟采样间隔和 4 个预测时域 $\{10, 30, 60, 120\}$ 分钟。对应的输入历史长度为 6 个时间步。空间离散化基于 H3：输入区域分辨率为 3，其父层输入分辨率为 2；目标细粒度分辨率为 $[3, 3, 2, 2]$，对应粗粒度分辨率为 $[2, 2, 1, 1]$。这一设置意味着 10 和 30 分钟预测仍保留较细空间粒度，而 60 和 120 分钟预测则在更宽的空间支撑上建模未来不确定性。

在层级推理阶段，粗区域 top-K 值统一设置为 $[64, 48, 48, 12]$。该设置兼顾了短时域更大的局部候选分支和长时域更粗空间分辨率下较小的父层类别规模。

5.3 比较模型

本文报告六类代表性模型。

1. **Markov baseline**：以当前输入区域为状态，统计从当前区域到未来区域和未来状态的经验转移频次，并使用加一平滑得到各 horizon 上的区域和状态概率。
2. **Hierarchical GRU**: 项目原始层级区域预测基线, 使用共享 GRU 时间摘要和 coarse-to-fine H3 输出头。
3. **Transformer Horizon Decoder**: 在层级 H3 输出头不变的条件下, 用单尺度 horizon-query Transformer 替代 GRU 共享时间摘要。
4. **Multiscale Transformer**：本文提出的最终模型，在单尺度 horizon-query 基础上加入显式粗尺度时间分支。
5. **TrAISformer-H3**：保留 TrAISformer 风格的因果离散序列建模结构，并将其输出端适配为本文统一的层级 H3 输出头。
6. **FlightBERT++-H3**：保留 FlightBERT++ 风格的非自回归 encoder-decoder 多 horizon 解码结构，并将原始飞行状态输出替换为本文统一的层级 H3 输出头。

这里的 TrAISformer-H3 和 FlightBERT++-H3 都是*适配基线*而非原论文任务的逐字复现。为了保证比较公平，我们固定了输入历史、预测时域、H3 输出空间、层级损失和评价指标，只允许时间建模主干和与之相关的训练超参数发生变化。相比之下，大量已有航空轨迹文献仍以短时坐标误差或局部空域点预测为中心，若不经过这一适配过程，无法直接与本文的区域概率预测协议进行同表比较。

5.4 训练设置与公平性说明

所有神经模型均在单张 CUDA GPU 上训练，使用 AdamW 优化器和固定随机种子 42。GRU 基线沿用项目原始 full 配置：batch size 为 1024，最大 epoch 为 400，最少训练 15 个 epoch，学习率调度阈值与早停阈值均为 5×10^{-4}。Transformer 家族模型（单尺度 ablation 和最终多尺度模型）统一采用 batch size 1024、8 个 DataLoader workers、混合精度训练、学习率 1.5×10^{-4}、weight decay 10^{-4}、梯度裁剪 1.0，并使用以下调度和早停配置：最大 epoch 1000、最少训练 8 个 epoch、ReduceLROnPlateau patience 4、factor 0.5、绝对阈值 3×10^{-4}、early stopping patience 8、min delta 3×10^{-4}。

对外部适配基线，我们保持相同的数据协议、输出头和评价协议，但允许采用各自稳定收敛所需的吞吐配置。具体而言，TrAISformer-H3 和 FlightBERT++-H3 使用 batch size 2048、12 个 workers、混合精度、学习率 2×10^{-4}，其余调度器和早停规则与 Transformer 家族模型保持一致。这样做的目的不是给予外部基线额外优势，而是避免把它们限制在明显次优的系统吞吐配置上。

最终 full-scale 训练的最佳验证损失和停止轮数分别为：Hierarchical GRU 不再以本文新协议重新调参；Transformer horizon decoder 在第 182 个 epoch 达到最优验证损失 0.3177；最终多尺度模型在第 182 个 epoch 达到最优验证损失 0.3055；TrAISformer-H3 在第 136 个 epoch 达到最优验证损失 0.3077；FlightBERT++-H3 在第 100 个 epoch 达到最优验证损失 0.3149。

5.5 评价指标

本文同时从分类性能、概率质量和候选区域效率三个层面评价模型。

模型	Top1	Top3	Top5	NLL	Brier	ECE	Union Cover	Union Cells	Union Area km^2	Cover@Budget
Markov 基线	0.3184	0.6166	0.7587	2.2788	0.8111	0.0323	0.8749	9.9542	545174	0.9699
层级 GRU	0.6648	0.9076	0.9631	1.0214	0.4578	0.0180	0.8931	2.4189	128965	0.9980
TrAISformer-H3	0.6803	**0.9178**	**0.9697**	**0.9556**	0.4361	0.0094	**0.8939**	2.2297	122810	**0.9983**
FlightBERT++-H3	0.6764	0.9144	0.9671	0.9791	0.4417	**0.0086**	0.8883	2.2023	**117593**	0.9982
Transformer horizon decoder	0.6744	0.9129	0.9656	0.9946	0.4447	0.0123	0.8920	2.2721	122553	0.9981
所提出的多尺度模型	**0.6827**	0.9174	0.9685	0.9641	**0.4338**	0.0093	0.8922	**2.1829**	118810	0.9983

表 1: 10、30、60 和 120 分钟预测时域上的完整规模宏平均比较。

分类性能。我们报告每个 horizon 上的 region top-1/top-3/top-5 命中率，并在主表中给出四个 horizon 的宏平均结果。状态预测同时输出 airborne/landed 概率，但在完整数据集上所有神经模型和 Markov 基线的状态准确率均接近 1.0，因此状态指标只保留为完整性报告，不作为区分模型优劣的主依据。

概率质量。区域概率通过 NLL、Brier 分数和 10-bin ECE 评价。对层级模型，评价时使用由粗区域分布与条件子区域分布组合得到的细粒度 H3 概率；若真值 coarse 和 child 标签都可用，则 NLL 还可精确写成真值粗区域概率与真值子区域条件概率的乘积形式。

候选区域效率。对每个 horizon，首先按概率从高到低选取细粒度 cell，直到累计概率质量达到 0.8 或达到 cell 预算 $B = [24, 18, 18, 24]$；再按 H3 1-ring 邻接关系把这些 cell 合并为连通组件，并按组件置信度排序。基于这一构造，本文报告：

1. *candidate union cover*（候选并集覆盖率）：真实目标 cell 是否落在全部候选组件并集中；
2. *candidate union cell count mean* 与 *candidate union area mean*：候选并集的平均规模与平均面积；
3. *Cover@Budget*（固定预算覆盖率）：只保留固定 cell 预算 B_j 个最高概率 cell 时的覆盖率；
4. *Area@Budget*：对应固定 cell 预算下的平均区域面积。

其中，候选并集覆盖率回答的是“在给定概率质量预算下，候选并集能否覆盖真实未来位置”；固定预算覆盖率则更直接反映固定空间预算下的召回能力。

5.6 默认后处理与消融设置

除非特别说明，主结果默认启用 reachability filter，不启用 H3 neighbor refinement。Reachability filter 根据当前 H3 cell 到目标 H3 cell 的球面距离剔除明显不可达的区域，阈值由最大速度 750 knots 和额外 250 km 余量共同决定。H3 refinement 则只在消融实验中使用，统一采用 1-ring 邻域，并测试 $\alpha \in \{0.05, 0.10, 0.20\}$ 三个概率扩散强度。此外，本文还单独报告关闭 reachability filter 的评价结果，以区分“模型本身的概率分布”与“几何可达性约束”对最终指标的贡献。

6 结果

6.1 完整规模主结果比较

表 1 报告四个预测时域上的宏平均结果。

结果有三点值得注意。首先，所有学习型层级模型都显著优于经典 Markov 基线。其次，在两个外部适配基线中，TrAISformer-H3 是最强竞争者：它取得最高的宏平均 top-3/top-5、最低的 NLL，以及最高的 union cover。第三，所提出的多尺度模型仍然保持最佳宏平均 top-1（0.6827）、

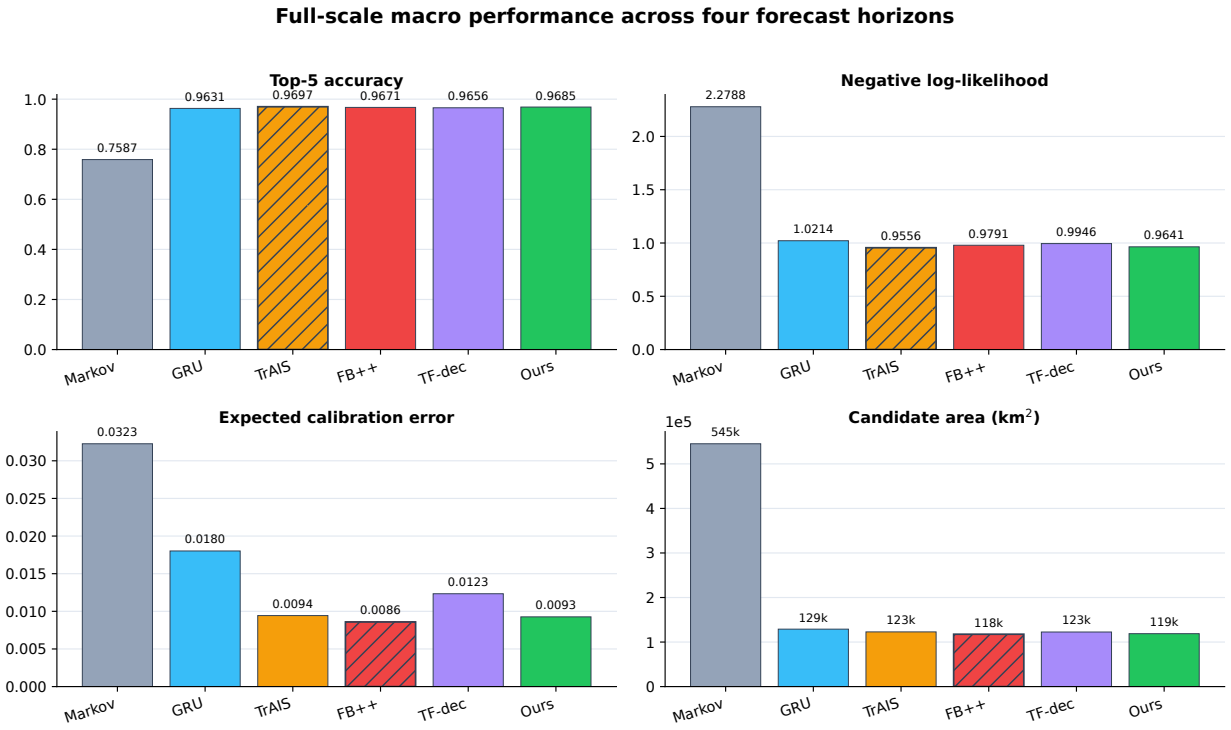


图 2: 完整规模主结果概览。相较内部基线和两个外部适配基线，所提出的多尺度模型在 top-1、Brier 分数和候选集合紧致性上保持整体最优平衡。

最佳 Brier 分数（0.4338）和最小的 candidate union cell 数（2.1829），说明它在分类正确性、概率质量和候选集合紧致性之间取得了更均衡的折中。

FlightBERT++-H3 呈现另一种行为模式。它的宏平均 ECE 最低（0.0086），候选 union 面积也最小（117,593 km^2），但 top-1/top-3/top-5 和 union cover 均低于所提模型。这说明更保守、更紧的候选集合并不自动意味着更好的整体区域预测；如果排序能力下降，候选覆盖也会同步退化。

从逐时域结果看，TrAISformer-H3 在 10 和 30 分钟时域上略优于所提模型的 top-3/top-5，但在 120 分钟时域上，所提模型重新取得明显优势：top-1 从 0.5481 提升到 0.5565，top-3 从 0.8482 提升到 0.8531，top-5 从 0.9355 提升到 0.9372，同时 NLL、Brier 和 ECE 也全部更优。这一现象支持本文的核心判断：显式多尺度时间建模的价值主要体现在中长时域区域预测，而不是只在短时排序指标上获益。

6.2 相较层级 GRU 基线的提升

相较层级 GRU 基线，所提模型提升了所有 top-k 指标和所有概率指标：top-1 从 0.6648 提升到 0.6827，top-3 从 0.9076 提升到 0.9174，top-5 从 0.9631 提升到 0.9685；NLL 从 1.0214 降至 0.9641，Brier 分数从 0.4578 降至 0.4338，ECE 从 0.0180 降至 0.0093。

提升在不同预测时域上具有一致性。表 2 给出了相较 GRU 基线的逐时域差值。

6.3 结构消融：多尺度分支是否必要

为了分离显式多尺度时间编码的价值，我们将最终模型与单尺度 Transformer horizon decoder 比较。后者已经具有时域专属 query，但不包含多尺度分支。

时域	ΔTop1	ΔTop3	ΔTop5	ΔNLL	ΔBrier	ΔECE	ΔUnion Cover	ΔUnion Cells	ΔUnion Area km^2
10m	+0.0199	+0.0059	+0.0031	-0.0516	-0.0281	-0.0085	-0.0004	-0.1864	-2316
30m	+0.0214	+0.0129	+0.0076	-0.0759	-0.0303	-0.0210	-0.0052	-0.3683	-4567
60m	+0.0115	+0.0054	+0.0018	-0.0340	-0.0158	-0.0016	+0.0023	-0.0908	-7705
120m	+0.0190	+0.0153	+0.0091	-0.0674	-0.0220	-0.0040	-0.0005	-0.2988	-26031

表 2: 所提模型相较层级 GRU 基线的逐时域差值。对于 top-k 和 union cover，正值更好；对于 NLL、Brier、ECE、候选 cell 和候选面积，负值更好。

模型	Top1	Top3	Top5	NLL	Brier	ECE	Union Cover	Union Cells	Union Area km^2
Transformer horizon decoder	0.6744	0.9129	0.9656	0.9946	0.4447	0.0123	0.8920	2.2721	122553
所提出的多尺度模型	**0.6827**	**0.9174**	**0.9685**	**0.9641**	**0.4338**	**0.0093**	0.8922	**2.1829**	**118810**

表 3: 单尺度 Transformer horizon decoder 与所提出多尺度模型的结构消融比较。

模型	Top5	NLL	Brier	ECE	Union Cover	Union Cells	Union Area km^2	Cover@Budget
最终模型	0.9685	0.9641	0.4338	0.0093	0.8922	2.1829	118810	0.9983
Refine a=0.05	0.9677	0.9593	0.4344	0.0310	0.9052	2.3315	127062	0.9987
Refine a=0.10	0.9673	0.9796	0.4372	0.0585	0.9192	2.5168	137220	0.9987
Refine a=0.20	0.9662	1.0340	0.4493	0.1135	0.9496	3.0980	167889	0.9987

表 4: 完整数据集上的 H3 邻域 refinement sweep。更高的 union cover 伴随更差的校准性和更大的候选集合。

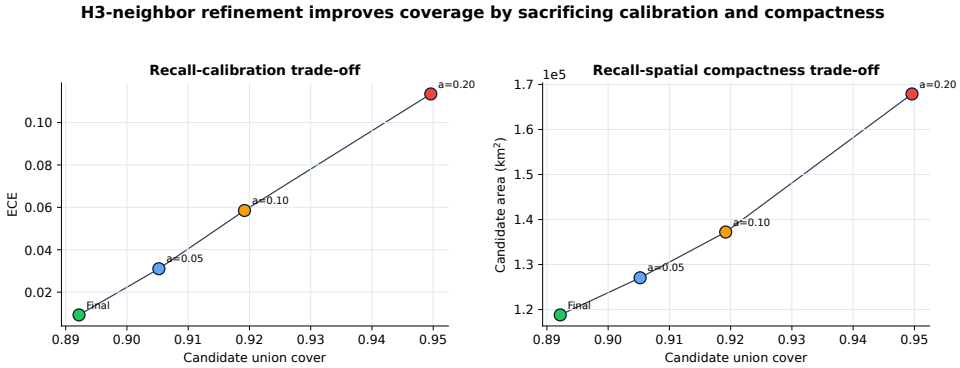


图 3: H3 邻域 refinement 提高候选 union cover，但额外召回以更差校准性和更大空间候选面积为代价。

多尺度分支改善了所有主要宏平均指标，并取得更低的验证损失（0.3055 对 0.3177）。这支持本文判断：显式双尺度时间建模带来的收益，并不只是把 GRU 替换为 Transformer 所能解释。

6.4 H3 邻域 refinement 体现召回与校准的权衡

接着，我们在三个扩散强度上评估 H3 邻域 refinement。该策略提高了概率质量候选召回，但不是无代价收益。

refinement 提高了候选 union cover，但很快损害校准性，并最终恶化 top-5 和 NLL。因此，它不应作为最终模型呈现。它的价值在于揭示一个具有运行意义的权衡：本地空间平滑可以提高召回，但会牺牲置信度质量和空间紧凑性。

6.5 Reachability filtering 的聚合影响较小

关闭 reachability filtering 只带来很小的聚合指标变化。这说明在当前设置中，reachability filtering 更像是一个可达性合理性保护，而不是预测收益的主要来源。

7 讨论

本文最重要的结果并不是简单证明 Transformer 优于 GRU。更关键的发现是：多时域区域航空预测受益于时域专属的时间检索和显式多尺度时间结构，同时仍然需要面向校准性的评估。模型可以通过更广泛地扩散概率质量来提高候选召回，但这类收益可能以置信度可靠性为代价。H3 refinement 消融正好揭示了这一点。

区域化表述本身也很重要。在开放运行数据上，尤其是 60 到 120 分钟预测时域，长距离点式轨迹回归容易制造一种并不可靠的精确感。本文采用的 H3 表述将不确定性显式化，支持层级推理，也允许下游用户在区域数量、覆盖面积和召回之间控制权衡。

同时，当前论文也有明确局限。首先，虽然整体框架在空间上是通用的，但本文实验使用的是 ADRR 中覆盖欧洲范围的商业交通，而不是真正意义上的全球数据。最终投稿时，标题和论述应准确反映这一经验范围。

其次，当前模型尚未纳入专门的缺失数据不确定性建模。预处理流程保留了 gap indicator，但预测模型本身还不是 GRU-D、连续时间潜变量动力学或 conformal regional prediction 意义上的显式不确定性感知模型。这应作为下一阶段工作，而不是当前论文的隐含贡献。

第三，外部航空基线受任务不匹配限制较大。现有许多文献处理短时坐标预测、终端区交互，或者依赖 ADRR 派生 artifact 中不可用的密集上下文输入。因此，本文采用了忠实于当前任务的基线层次：Markov、层级 GRU、Transformer horizon decoder 和所提出的多尺度模型。

这些局限并不削弱当前贡献，反而界定了清晰的后续研究方向：gap-aware 不确定性建模、calibration-aware 后处理，以及更广泛的跨数据集验证。

8 结论

本文基于 ADRR 派生开放航空数据，对多时域区域航空轨迹预测进行了大规模实验研究。以层级 H3 GRU 基线为起点，我们引入 horizon-query Transformer decoder，并进一步加入显式多尺度时间分支。最终模型相较 GRU 基线和单尺度 Transformer 消融模型，在 top-k 准确率、NLL、Brier 分数和校准性上均取得提升，同时生成更小的候选区域集合。经典 Markov 基线明显较弱，这说明该任务需要比简单经验转移建模更强的时间表示学习能力。

H3 refinement 实验进一步说明，候选召回和校准性应当一起报告。一个激进扩展候选区域的模型，在只看召回时可能显得更强，但其概率可信度会下降。因此，大规模区域航空预测应被评估为准确性、不确定性质量和空间效率的联合问题。

总体而言，实验结果支持将层级 H3 预测与多尺度 horizon-query 时间编码结合，作为开放轨迹档案上长时域区域航空预测的强基线。它也为下一步方法研究提供了稳定基础：在缺失和不规则飞行观测下，进一步构建显式不确定性感知的区域预测模型。

数据可用性与可复现性

本文实验使用一个月的飞行轨迹，数据来源于 EUROCONTROL Aviation Data Repository for Research（ADRR）[3]。EUROCONTROL 按其使用条款向研究和开发用途提供 ADRR 访问，但原始数据不能由本文作者公开再分发。为支持可复现性，项目仓库包含用于标准化 ADRR 数据的端到端预处理脚本、所有报告实验的配置文件、所有比较方法的模型实现、实验日志和评估摘要，以及用于重建开发子集和重新运行完整实验的脚本。

参考文献

[1] Matthias Schäfer, Martin Strohmeier, Vincent Lenders, Ivan Martinovic, and Matthias Wilhelm. Bringing up opensky: A large-scale ADS-B sensor network for research. In *Proceedings of the 13th International Symposium on Information Processing in Sensor Networks*, pages 83–94. IEEE, 2014. doi: 10.1109/IPSN.2014.6846743. URL https://doi.org/10.1109/IPSN.2014.6846743.

[2] Martin Strohmeier, Xavier Olive, Jannis Lübbe, Matthias Schäfer, and Vincent Lenders. Crowdsourced air traffic data from the OpenSky network 2019–2020. *Earth System Science Data*, 13:357–366, 2021. doi: 10.5194/essd-13-357-2021. URL https://doi.org/10.5194/essd-13-357-2021.

[3] EUROCONTROL. Aviation data repository for research (ADRR). https://www.eurocontrol.int/dashboard/aviation-data-research, 2025. Accessed 2026-05-21.

[4] Peiyan Jia, Huiping Chen, Lei Zhang, and Daojun Han. Attention-LSTM based prediction model for aircraft 4-D trajectory. *Scientific Reports*, 12, 2022. doi: 10.1038/s41598-022-19794-1. URL https://doi.org/10.1038/s41598-022-19794-1.

[5] Zheng Zhang, Dongyue Guo, Shizhong Zhou, Jianwei Zhang, and Yi Lin. Flight trajectory prediction enabled by time-frequency wavelet transform. *Nature Communications*, 14:5258, 2023. doi: 10.1038/s41467-023-40903-9. URL https://doi.org/10.1038/s41467-023-40903-9.

[6] Dongyue Guo, Zheng Zhang, Zhen Yan, Jianwei Zhang, and Yi Lin. FlightBERT++: A non-autoregressive multi-horizon flight trajectory prediction framework. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pages 127–134, 2024. doi: 10.1609/aaai.v38i1.27763. URL https://doi.org/10.1609/aaai.v38i1.27763.

[7] Youyou Li, Yuxiang Fang, and Teng Long. Noise robust aircraft trajectory prediction via autoregressive transformers with hybrid positional encoding. *Scientific Reports*, 15, 2025. doi: 10.1038/s41598-025-96512-7. URL https://doi.org/10.1038/s41598-025-96512-7.

[8] Ruiyan Shan, Liquan Dong, Kang Li, and Lianqing Dong. A deep learning framework for predicting aircraft trajectories from sparse satellite observations. *Scientific Reports*, 15, 2025. doi: 10.1038/s41598-025-27064-z. URL https://doi.org/10.1038/s41598-025-27064-z.

[9] Lan Ma, Xianran Meng, and Zhijun Wu. Data-driven 4D trajectory prediction model using attention-TCN-GRU. *Aerospace*, 11(4):313, 2024. doi: 10.3390/aerospace11040313. URL https://doi.org/10.3390/aerospace11040313.

[10] Dongyue Guo, Zheng Zhang, Jiayi Liu, Jianwei Zhang, and Yi Lin. Multi-horizon flight trajectory prediction enabled by time-frequency wavelet transform. *Nature Communications*, 17:633, 2026. doi: 10.1038/s41467-025-67399-9. URL https://doi.org/10.1038/s41467-025-67399-9.

[11] Bryan Lim, Sercan Ö. Arik, Nicolas Loeff, and Tomas Pfister. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37 (4):1748–1764, 2021. doi: 10.1016/j.ijforecast.2021.03.012. URL https://doi.org/10.1016/j.ijforecast.2021.03.012.

[12] Carson Eisenach, Yagna Patel, and Dhruv Madeka. MQTransformer: Multi-horizon forecasts with context dependent and feedback-aware attention, 2020. URL https://arxiv.org/abs/2009.14799.

[13] Duong Nguyen and Ronan Fablet. TrAISformer: A transformer network with sparse augmented data representation and cross entropy loss for AIS-based vessel trajectory prediction, 2021. URL https://arxiv.org/abs/2109.03958.

[14] Tilmann Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007. doi: 10.1198/016214506000001437. URL https://doi.org/10.1198/016214506000001437.

[15] Glenn W. Brier. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1):1–3, 1950. doi: 10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2. URL https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2.

[16] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70 of *PMLR*, pages 1321–1330, 2017. URL https://proceedings.mlr.press/v70/guo17a.html.

[17] Kevin Sahr, Denis White, and A. Jon Kimerling. Geodesic discrete global grid systems. *Cartography and Geographic Information Science*, 30(2):121–134, 2003. doi: 10.1559/152304003100011090. URL https://doi.org/10.1559/152304003100011090.

[18] H3 Contributors. H3 core library overview. https://h3geo.org/docs/core-library/overview, 2025. Accessed 2026-05-21.