全球航空轨迹多时间尺度区域预测

组会汇报 | 方法原理与实验结果

研究目标

基于大规模开放航空轨迹数据，预测未来 10/30/60/120 分钟所在 H3 区域分布。

关注的不只是 top-k 命中，还包括概率质量、候选区域紧致性和长时域稳定性。

当前定位

任务：层级 H3 区域概率预测，而不是传统经纬度点回归。

数据：ADRR 构建的 2024 年 3 月商业航班档案，full-scale 约 2071 万窗口。

方法主线：从 hierarchical GRU 演化到 multiscale horizon-query Transformer 。

汇报重点 1：为什么把问题定义成层级 H3 区域预测

汇报重点 2：所提出多尺度模型的核心结构

汇报重点 3：与内部基线、外部 adapted baselines 的对比结果

问题定义

输入历史轨迹，输出未来多个 horizon 的层级 H3 区域概率

输入

30 分钟历史窗口， 5 分钟采样，共 6 个时间步。

每步包含： H3 区域 id 、父层区域 id 、 18 维数值特征、 2 维 mask 特征。

附加 9 维上下文特征。

输出

预测 horizon： 10 / 30 / 60 / 120 min 。

对每个 horizon 同时预测： coarse H3 、 child H3 、 airborne/landed 状态。

细粒度目标分辨率： [3,3,2,2] 。

评价

分类： Top1 / Top3 / Top5

概率质量： NLL / Brier / ECE

候选区域： Union Cover / Union Cells / Union Area / Cover@Budget

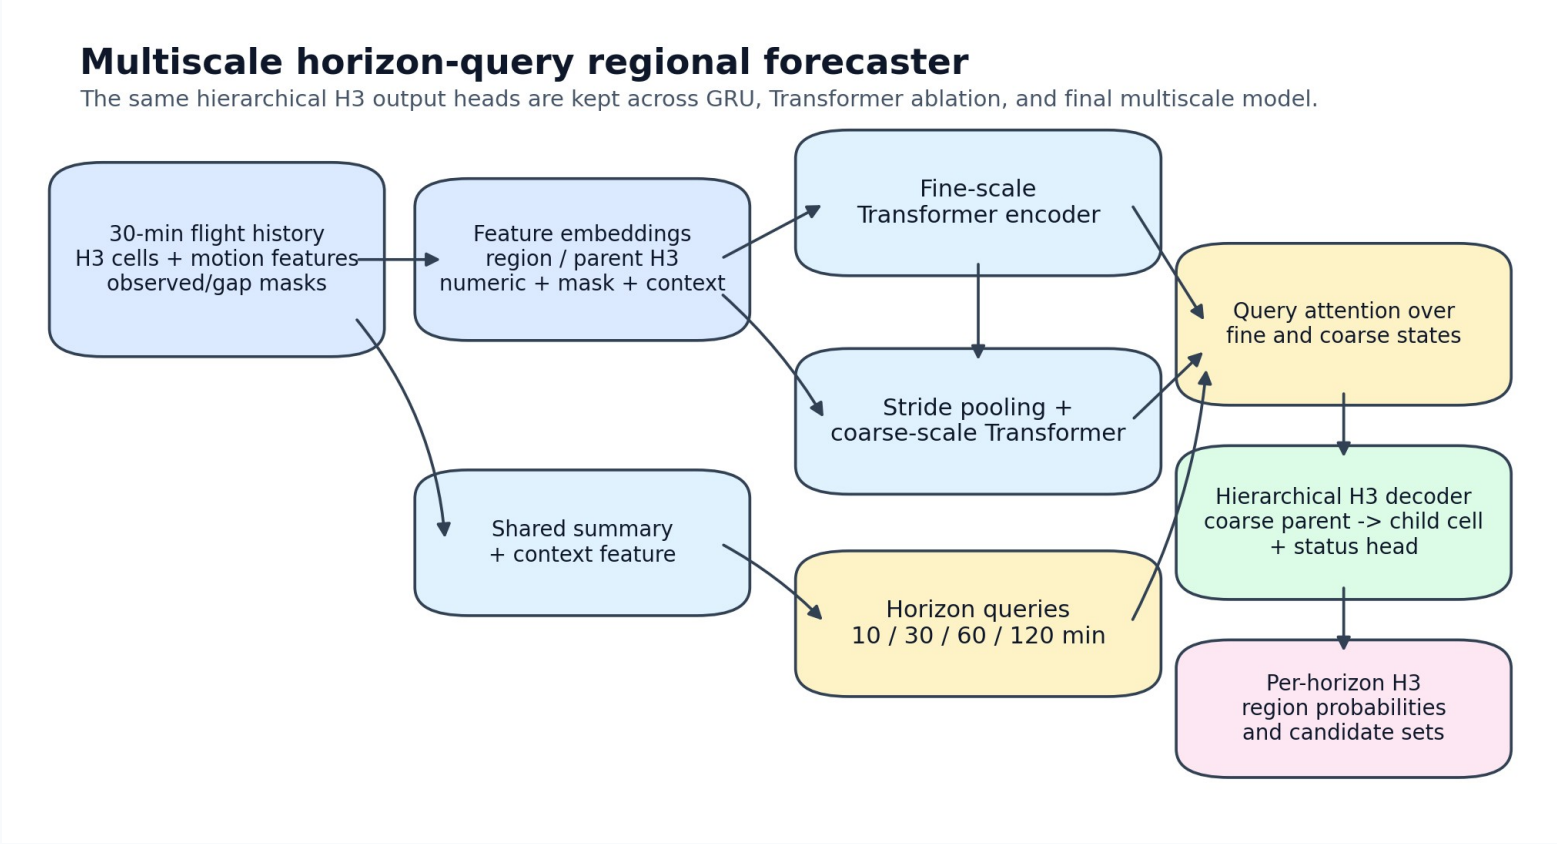
为什么不用单点坐标误差：对于空管 / 区域监控场景，更关心未来落在哪些可操作区域中。

为什么做层级预测：直接在巨大细粒度空间上分类太难， coarse-to-fine 更符合 H3 父子层级。

为什么看候选区域：高 top-k 但候选区域过大，运行价值仍然有限。

方法框架

统一层级 H3 输出头 + horizon-aware 时间建模



核心演化路径

Hierarchical GRU：所有 horizon 共用一个时间摘要，长短时域共享同一表示。

Single-scale horizon-query Transformer：不同 horizon 用不同 query 从历史中读取信息。

Multiscale Transformer：在此基础上增加显式粗尺度时间分支。

关键直觉

10/30 分钟更依赖局部机动信息。

60/120 分钟更依赖阶段性趋势和粗尺度演化。

因此，用一个单尺度时间摘要往往不够。

所提出模型的关键设计

多尺度 horizon-query Transformer 关注中长时域区域预测

细尺度分支：保留 6 步历史序列，捕捉局部机动与短期区域切换。

粗尺度分支：对细尺度序列做 stride=2 的 masked pooling，再做额外 Transformer 编码。

每个 horizon 有独立 query，同时从 fine/coarse 两个时间尺度读取信息，再融合成该 horizon 的解码特征。

输出端统一采用 coarse-to-fine H3 头，保证和所有内部 / 外部 baseline 在同一输出协议下比较。

为什么这套设计合理

不直接换任务定义，只替换时间建模主干。

既能和 GRU 比，也能和 adapted external baselines 比。

理论上更适合长时域信息抽取，实验中确实在 120 分钟上更稳。

推理后处理

默认启用 reachability filter。

H3 refinement 只作为消融，不作为最终方法。

主结果对比

与内部基线和外部 adapted baselines 的 full-scale 宏平均比较

模型	Top1	Top3	Top5	NLL	Brier	ECE
Markov	0.3184	0.6166	0.7587	2.2788	0.8111	0.0323
层级 GRU	0.6648	0.9076	0.9631	1.0214	0.4578	0.0180
TrAISformer-H3	0.6803	0.9178	0.9697	0.9556	0.4361	0.0094
FlightBERT++-H3	0.6764	0.9144	0.9671	0.9791	0.4417	0.0086
单尺度 Transformer	0.6744	0.9129	0.9656	0.9946	0.4447	0.0123
所提多尺度模型	0.6827	0.9174	0.9685	0.9641	0.4338	0.0093

读表结论

TrAISformer-H3 是当前最强 external baseline。

所提多尺度模型取得最佳 Top1、最佳 Brier、最低候选 cell 数。

FlightBERT++-H3 的 ECE 最低，但整体 top-k 不如前两者。

汇报时建议的口径

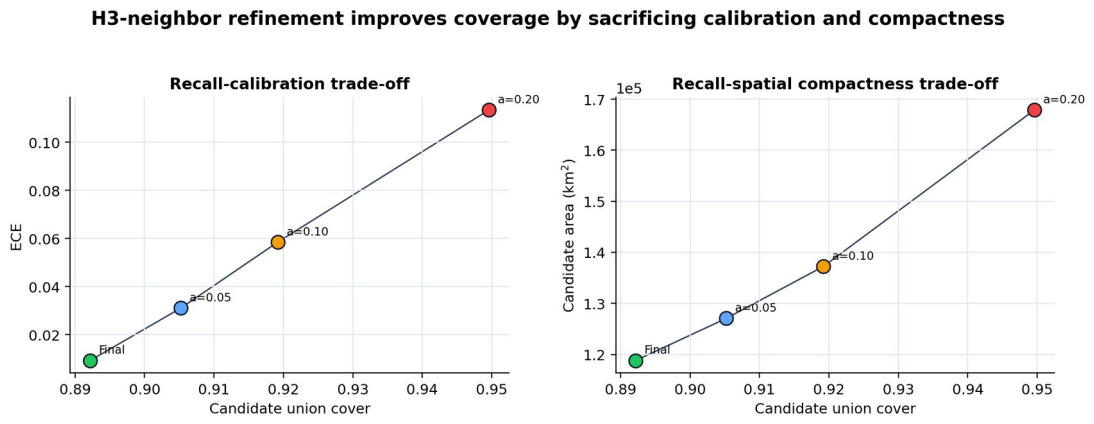
不要说“全面最好”。

更稳妥的说法是：在强 baseline 存在的情况下，所提方法在首选命中、概率质量和候选紧致性之间更均衡。

结构消融与后处理分析

多尺度分支是有效的， H3 refinement 更像召回 - 校准权衡

模型	Top1	Top5	NLL	Brier	ECE
单尺度 Transformer	0.6744	0.9656	0.9946	0.4447	0.0123
所提多尺度模型	0.6827	0.9685	0.9641	0.4338	0.0093



消融结论 1： 多尺度分支必要

相较单尺度 Transformer，所提模型在 Top1/Top5/NLL/Brier/ECE 上全部更优。

因此收益不只是“把 GRU 换成 Transformer”。

消融结论 2： H3 refinement 不适合作为最终方法

它能提高覆盖率，但会恶化校准并扩大候选区域。

更适合被解释为运行中的召回 - 校准权衡工具。

当前结论与下一步

主线已经清晰，接下来重点补强结果叙事和解码侧优化

结论 1：层级 H3 多 horizon 区域预测在大规模开放航空轨迹数据上是可行的。

结论 2：多尺度 horizon-query Transformer 相较项目原始 GRU 基线有稳定提升。

结论 3：强 external baseline 存在，说明任务并不容易，当前方法的优势主要体现在 Top1 、 Brier 和候选紧致性。

下一步计划

优先做 evaluation-only 解码 sweep，尝试用更大的 parent top-k 改善 Top5/NLL 。

若仍需结构改进，再考虑针对短时排序能力补强，而不是直接改更细网格。

论文层面强调：最终方法不是“全指标最好”，而是“更均衡的运行型方案”。